能源动力硕士学位论文

基于深度学习和协同过滤的音乐推荐系统研究

刘昊

吉林建筑大学

2023 年 6 月

中国知网 https://www.cnki.net

国内图书分类号：TP183
国际图书分类号：621.3

能源动力硕士学位论文

基于深度学习和协同过滤的音乐推荐系统研究

硕 士 研究生：刘昊

导　　师：郭秀娟教授

申 请 学 位：能源动力硕士

学 科、专 业：能源动力(电气工程)

所 在 单 位：电气与计算机学院

答 辩 日 期：2023 年 6 月

授予学位单位：吉林建筑大学

中国知网　https://www.cnki.net

Classified Index: TP183
U.D.C: 621.3

Dissertation for the Master Degree in Energy and Power

Research on Music Recommendation System Based on Deep Learning and collaborative filtering

Candidate:	**Liu Hao**
Supervisor:	**Prof. Guo Xiujuan**
Academic Degree Applied for:	**Master of Energy and Power**
Speciality:	**Energy and Power (Electrical Engineering)**
Affiliation:	**School of Electrical and Computer Science**
Date of Defence:	**June,2023**
Degree-Conferring-Institution :	**JiLin Jianzhu University**

中国知网 https://www.cnki.net

摘　要

随着互联网的飞速发展，数据量也随之爆炸式增长。对于音乐软件的用户来说，音乐库的规模已经增长到一个十分惊人的程度，过往的音乐系统仅仅通过信息检索的方式进行一定程度的过滤，但这远远达不到用户的预期，用户想要找到一首符合自己兴趣的音乐仍然需要耗费不小的时间成本。因此个性化音乐推荐系统诞生的目标之一就是在庞大的音乐数据库中精准地为用户推荐其感兴趣的音乐。

本文对国内外的音乐推荐系统发展现状进行了研究，设计了音乐分类模型FCGRNN。FCGRNN 由全卷积网络和循环神经网络联合组成，在音乐分类任务中比之 CNN 具有能够发觉更深层次的时间空间特征的优点，也比 RNN 具有更少的参数量，这使得模型在具有更高分类精度的同时更轻量级，便于储存参数；提出了基于降噪自动编码器的推荐和基于标签的推荐的混合推荐模型，此模型也在传统协同过滤推荐算法的基础上引入了降噪自动编码器与基于标签的混合推荐，对两种推荐算法的权值比重进行动态调整，最终给出推荐列表。推荐系统则是基于 Java 语言、JavaScript 语言以及其各个框架的应用，使用一站式的 Springboot 框架和 Vue 框架进行 web 端开发，Springboot 框架具有由于不需要进行各种繁琐的配置而能够大大缩短开发周期的优点，Vue 框架可以进行组件化开发，大大减少代码编写量，其响应式界面可以更好的渲染数据。推荐系统能够实时记录用户的操作和反馈，进而影响推荐模型给出的推荐结果。参考当前互联网上比较优秀的音乐软件，合理分析用户需要，设计所需系统功能模块、良好的用户交互界面，实现一个较为精准好用的个性化音乐推荐系统。

关键词 协同过滤；卷积神经网络；循环神经网络；降噪自动编码器；推荐系统

中国知网 https://www.cnki.net

Abstract

With the rapid development of the Internet, the amount of data has also exploded. For users of music software, the size of the music library has grown to a very astonishing extent. In the past, music systems only used information retrieval to filter to a certain extent, but this far fell short of user expectations. Users still need to spend a considerable amount of time and cost to find a music that suits their own interests. Therefore, one of the goals of the birth of personalized music recommendation systems is to accurately recommend the music that users are interested in in in a large music database.

This article studies the current development status of music recommendation systems both domestically and internationally, and designs a music classification model FCGRNN. FCGRNN is composed of a combination of fully convolutional networks and recurrent neural networks. Compared to CNN, it has the advantage of detecting deeper temporal and spatial features in music classification tasks, and has fewer parameter quantities. This makes the model more lightweight and convenient for storing parameters while achieving higher classification accuracy; A hybrid recommendation model which is based on denoising automatic encoder recommendation and based on label recommendation is proposed. This model also introduces hybrid recommendation, which is a recommendation model based on denoising automatic encoder and label, on the basis of the traditional collaborative filtering recommendation algorithm, dynamically adjusts the weight of the two recommendation algorithms, and finally gives a recommendation list. The recommendation system is based on the application of Java language, JavaScript language, and various frameworks, using a one-stop Springboot framework and Vue framework for web development. The Springboot framework has the advantage of greatly shortening the development cycle without the need for various cumbersome configurations. Vue framework can be used for componentization development, greatly reducing the amount of code writing, and its responsive interface can better render data. The recommendation system can record user actions and feedback in real-time, which in turn affects the recommendation results provided by the recommendation model. Referring to the current excellent music software on the internet, analyze user needs reasonably, design the required system functional modules, and provide a good user interaction interface to achieve a more accurate and user-friendly personalized music recommendation system.

中国知网 https://www.cnki.net

Keywords collaborative filtering; convolutional neural network; recurrent neural network; denoising automatic encoder; recommendation system

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 个性化服务.....2
1.2.2 推荐技术.....2
1.3 论文结构.....3
1.3.1 论文结构.....3
1.3.2 技术路线图.....5
第 2 章 推荐系统基础知识.....6
2.1 推荐算法基本原理.....6
2.1.1 基于内容的推荐算法.....6
2.1.2 协同过滤推荐算法.....7
2.1.3 基于深度学习的推荐算法.....9
2.2 衡量推荐算法性能的指标.....14
2.3 Springboot 框架.....15
2.3.1 Spring Boot 的优势.....16
2.3.2 Springboot 的自动配置原理.....17
2.4 Mybatis 框架.....17
2.4.1 Mybatis 的优势.....18
2.4.2 Mybatis 的运行流程.....19
2.5 模板引擎 Thymeleaf.....20
2.5.1 Thymeleaf 的特点.....21
2.6 MySQL.....21
2.6.1 MySQL 特点.....21
2.6.2 MySQL 数据库存储引擎.....22
2.7 本章小结.....23
第 3 章 音乐推荐系统模型.....24
3.1 当下音乐推荐系统的常见问题.....24
3.2 数据集与特征工程.....25
3.2.1 数据来源.....25
3.2.2 建立用户评分矩阵.....26
3.3 特征提取.....27
3.3.3 FCGRNN 网络模型结构.....30
3.4 混合推荐模型.....31

中国知网 https://www.cnki.net

3.5 实验结果分析.....32
3.5.1 音频特征提取结果分析.....32
3.5.2 推荐模型结果分析.....34
3.6 本章小结.....36
第 4 章 音乐推荐系统设计.....37
4.1 需求分析.....37
4.1.1 用户功能分析.....37
4.1.2 管理员功能分析.....38
4.1.3 系统基础功能分析.....39
4.2 数据库设计.....40
4.2.1 数据库设计原则.....40
4.2.2 表属性介绍.....41
4.2.3 表结构设计.....42
4.3 系统整体设计.....44
4.4 本章小结.....45
第 5 章 推荐系统的实现.....46
5.1 用户核心模块实现.....46
5.1.1 登陆注册模块.....46
5.1.2 发现音乐模块.....47
5.1.3 我的歌单模块.....49
5.1.4 私人 FM 模块.....49
5.1.5 关注模块.....50
5.2 管理员核心模块实现.....51
5.2.1 用户信息管理模块.....51
5.2.2 音乐信息管理.....52
5.2.3 推荐信息管理.....52
5.2.4 播放信息管理.....53
5.3 本章小结.....54
总结和展望.....55
参考文献.....56

中国知网 https://www.cnki.net

第 1 章 绪论

个性化音乐推荐系统的主要任务就是能够高效地替用户在海量的音乐库中寻找到用户所感兴趣的音乐。协同过滤推荐算法作为如今应用最广泛的推荐算法，在各个领域都有其应用。但是协同过滤的缺点也随着大数据时代到来而愈发明显。综合各个传统推荐算法的优缺点，结合深度学习的混合推荐算法已经成为了研究的方向。

1.1 研究背景及意义

2021 年 2 月 3 日发布的第 47 次《中国网络发展情况的统计报告》指出，截至 2020 年 12 月，我国网民规模达 9.89 亿，较 2020 年 3 月增长 8540 万，互联网普及率达 70.4%，较 2020 年 3 月提升 5.9 个百分点[1]。伴随而来的是巨大的数字音乐市场，即使在疫情导致的世界经济低迷、中美经贸摩擦的背景下，数字音乐产业仍然高速增长，增长率超过 8%[2]。

1995 年 3 月，卡耐基梅隆大学的 Robert Armstrong 等提出了个性化导航系统 Web Watcher，首次提出了个性化推荐这个概念。个性化推荐经过许多年的发展，人们生活中的诸多方面都有其身影。随着互联网规模的日益增长，数据规模的问题也不可忽视，在音乐领域中，随着曲库的不断扩大，音乐资源也不断增加，导致用户们无法快速精准地找到自己所钟意的音乐。而音乐软件的搜索引擎，只是机械式得检索数据库而不会考虑到用户间的差异，对音乐的偏好是因人而异的，进而导致用户对音乐软件的印象只是个音乐播放器与搜索器。音乐软件想要提高用户的满意度就需要能够为用户提供精准的个性化推荐服务，如此可以有效提高用户对平台的粘性，才能从各种音乐软件中突出。

因此，能够得出优秀的推荐系统一定要具有精准的个性化推荐功能的结论。个性化音乐推荐系统能够根据音乐的本身音频特征和用户的历史行为，推测出用户对各种音乐的喜好程度，生成推荐列表。此外，本课题所研究的推荐系统不仅要能够为用户进行个性化推荐，还要有一个音乐软件该有的完整功能，例如可以收藏喜欢的音乐、查看音乐的相关信息等功能。这种音乐推荐系统既可以准确地推荐给用户喜欢的音乐，又可以使用户有完整的软件体验，极大增强用户的使用兴趣。所以，该系统拥有非常好的应用场景。

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 个性化服务

如今互联网的普及率已经超过了 70%，大众也大多从网上获取自己想要的信息。听音乐也不例外，随着各类音乐软件的发展，以及越来越多音乐人的诞生，如今衡量一个音乐软件的好坏已经从音乐软件曲库的数量转变成看这个音乐软件是否有优秀的音乐信息服务。面对规模巨大的音乐库，简单的播放或者下载已经满足不了用户的需要，用户们都需要音乐软件平台能够提供优质的个性化推荐。Baccigalupo Claudio 和 Plaza Enric 认为认为用户应该更加认可由推荐的歌曲组成的歌单的推荐列表，单个推荐结果无法满足用户的需求[4]。大众的日常生活已经离不开网络音乐，听音乐能够效缓解人们的压力，能够让人们过快的生活节奏稍微放缓一点[5]。

我国音乐推荐系统的发展相对来说起步较晚，并且个性化推荐音乐的能力也较弱，但是也有一些比较优秀的互联网音乐产品如网易云、咪咕音乐、QQ 音乐等，但他们更注重的还是通过音乐进行社交，如深得人心的网易云音乐的评论功能和对平台中好友的分享等行为，互动似的去为用户推荐感兴趣的音乐[6]。但用户对于音乐的喜好跟用户所处的环境也有很强的关联性，如天气、时间、场景等，用户对音乐的偏好就会发生一些周期性的变化[6]。所以音乐推荐系统需要考虑这些因素并进行动态调整，实现针对用户的痛点进行个性化推荐[7]。

国内的音乐推荐系统发展至今也有一些优秀的音乐软件，如网易云音乐、咪咕音乐、QQ 音乐等。这些音乐软件的侧重点不同，有的音乐软件偏向于社交，主要通过好友之间的互动或者推荐附近的相似用户来吸引用户；有的通过音乐推荐系统的精准推荐吸引用户，但是由于发展起步较晚，效果也不是很明显[6]。随着近年来人工神经网络的发展，卷积神经网络用于推荐预测也是一种研究方向[6]。另一方面用户的喜好也不是固定的，可能会随着时间点、季节、场景、天气而发生变化，推荐时也要考虑到各个方面的因素而进行推荐[7]。

1.2.2 推荐技术

在 1992 年，D.Goldberg 为了解决研究中心邮件数量过载问题，提出 Tapestry，它是首个协同过滤推荐模型[8]。最早的推荐系统可以追朔到 1994 年，是由 GroupLens 研究组设计研究出的名为 GroupLens 的新闻推荐系统[9]。2000 年，D. Bollacker 等人将 CiteSeer 个性化[9]；首个个性化推荐视频的网站 PTV 出现；

中国知网 https://www.cnki.net

同年，为了发展个性化服务研究项目，多个国际组织和基金会拨款投入研发。这一年，我国的个性化服务也开始发展。其中具有代表性的是由清华大学的路海明等和南京大学的潘金贵等推出的基于多 Agent 实现个性化推荐、个性化信息搜索智能体 DOLTRI-Agent。至此，网络应用技术研究多了一个新热点，让学者看清了研究方向、让音乐软件公司看到了新商机。发展至今，个性化推荐的研究成果给我广大的音乐用户提供了极大的便利，给各大音乐软件平台带去了巨大的收益。

算法层面的改进随着个性化推荐的不断地深入研究发展已经无法进一步深入，但是近年来深度神经网络的研究热潮再一次推动了推荐系统的发展，混合深度神经网络和传统推荐算法的推荐模型已成必然。

随着用户个性化需求的日益增长，国内外音乐软件平台也更加关注音乐推荐领域的发展。协同过滤推荐算法作为应用最为广泛的推荐算法，也同样被应用于音乐推荐领域。如 González 等人，定义一种新的用于计算用户之间的相似度的指标，这个指标是通过发掘隐含在用户与用户之间的社交中的规则而定义的[11]。大数据时代下，用户和项目都数目庞大，但是不可能有用户能接触所有项目，也不可能有项目会被所有用户接触，甚至用户只能接触少部分的项目，这就体现了传统协同过滤推荐算法的两个问题——高稀疏性和冷启动问题，而深度神经网络只需要拥有足够的训练集，因此将二者融合能很好的解决这个问题。针对解决稀疏性问题，Kai 等提出利用卷积神经网络和改进后的自动编码器挖掘隐式规则，再融合协同过滤推荐模型，成功解决了评分矩阵的高稀疏性带来的问题[12]。而针对解决冷启动问题，Zhong 等人提出了一种简单有效的卷积神经网络(MCRN)，这种卷积神经网络用可以学习音乐的音频特征，通过傅里叶变换将音频转换成“频谱图”，通过频谱图进行训练学习，有效地从频谱中提取音乐特征，证明了音乐推荐分类网络在音乐频谱分类上具有更高的精度[13]。不仅仅是卷积神经网络，循环神经网络也能在音乐推荐系统中占据一定地位。Zhao 等人通过获取音乐的长期记忆以及上下文内容来训练一个长短时记忆网络，最后生成音乐推荐列表，通过实验证明了循环神经网络的可行性[14]。Zheng 等人通过加入注意力机制优化循环神经网络模型存在的梯度消失问题，，从而提高了音乐分类的准确性，成功解决了音乐分类任务存在的问题[15]。

1.3 论文结构

1.3.1 论文结构

第 1 章为绪论。阐述课题的研究背景和意义，回顾国内外个性化音乐推荐

中国知网 https://www.cnki.net

系统的发展历程、基于深度学习和协同过滤推荐算法的现状，分析目前各类神经网络的应用场景，对存在的问题进行剖析总结。

第 2 章为推荐系统基础知识，包含了音乐推荐系统模型的设计基础知识及开发的设计基础知识。首先介绍了几种传统的推荐算法基本原理，阐述了深度神经网络的应用场景，重点介绍本文所用的推荐算法和深度神经网络模型，其次衡量推荐系统的两个指标进行了介绍概括，最后介绍了推荐系统开发时所需要用到的编程语言、框架、引擎、数据库等。

第 3 章为推荐系统模型设计，分析设计了音乐推荐系统模型。提出了音乐分类模型，使用联合全卷积网络和循环神经网络构成 FCGRNN，介绍了其网络结构，同时提出一种在自建数据集没有显式评分的条件下通过用户播放音乐的次数构建用户评分矩阵的方法。提出了混合基于降噪自动编码器的协同过滤推荐算法和基于标签的推荐算法的混合推荐模型，通过数据实验验证了此推荐模型要优于传统的推荐算法。

第 4 章为推荐系统开发设计。通过对推荐系统开发进行需求分析，根据需求分析设计数据库的表结构、系统开发时的编程环境版本信息。

第 5 章根据需求分析和数据库设计实现了音乐推荐系统。

第 6 章回顾了本文的主要工作，并对音乐推荐系统的不足提出了展望。

中国知网 https://www.cnki.net

1.3.2 技术路线图

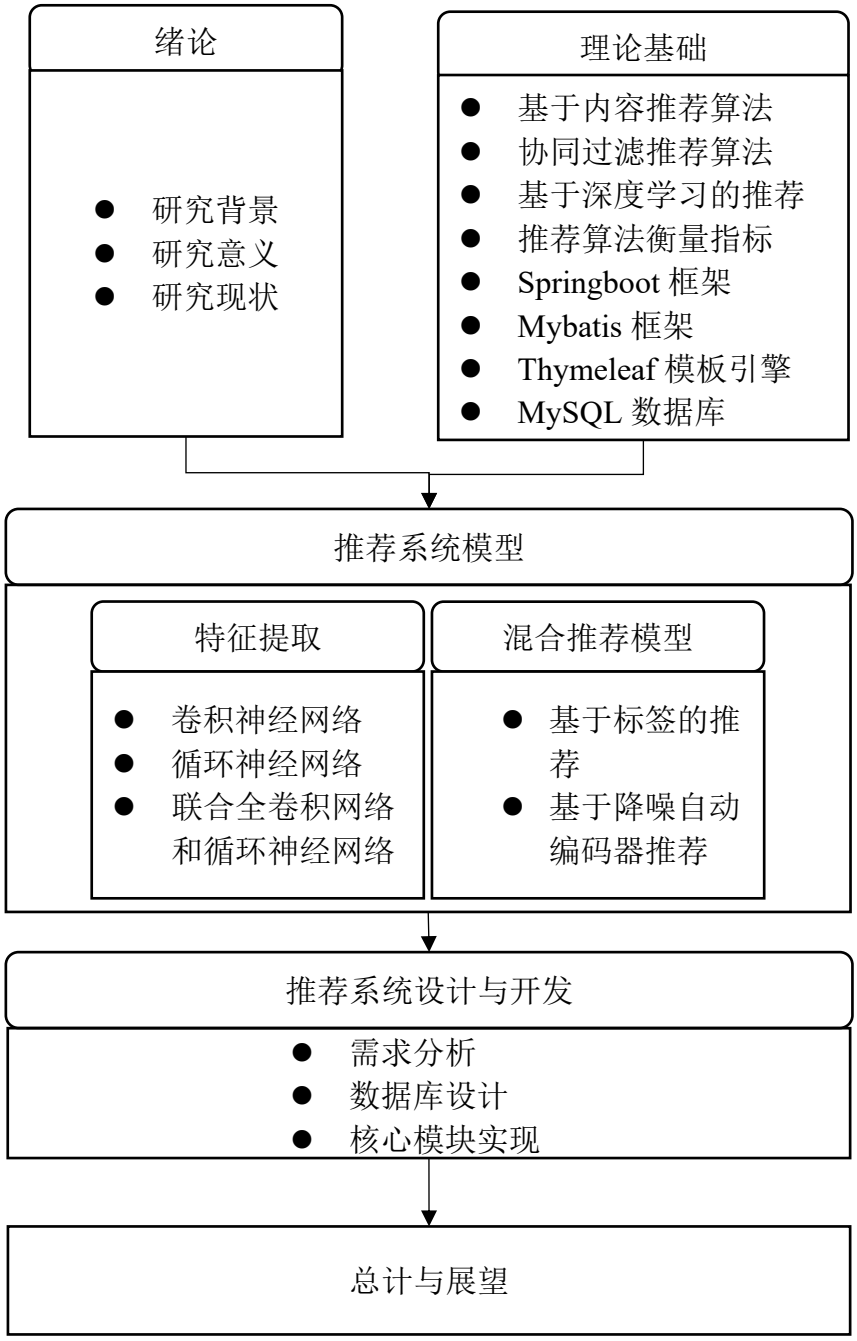

图 1-1 技术路线图

Figure 1-1 Technical Roadmap

中国知网 https://www.cnki.net

第 2 章 推荐系统基础知识

本章简单介绍常见的推荐算法、深度神经网络基本原理，重点介绍本文提出的相关推荐算法和深度神经网络的基本原理、衡量推荐算法的指标、系统开发需要用到的几个框架的基本原理。

2.1 推荐算法基本原理

推荐算法根据已有数据，提取用户与项目之间、用户与用户之间或者项目与项目之间的隐含关系，再结合用户的自身偏好，给出推荐结果[16]。

2.1.1 基于内容的推荐算法

所谓基于内容的推荐，就是对某一个用户的所有数据建立矩阵进行特征提取操作，构建用户的偏好模型，再将待推荐项目的内容特征与用户的偏好模型之间计算相关度，最后给出推荐结果。

对用户进行特征提取时需要获得用户对项目的反馈，包含显示反馈和隐式反馈。显示反馈是指用户对这个项目内容的更明显评分行为，例如点赞、转发、关注、打赏等；隐式反馈则是用户对项目的浏览记录等隐含规则，算法如图 2-1。

中国知网 https://www.cnki.net

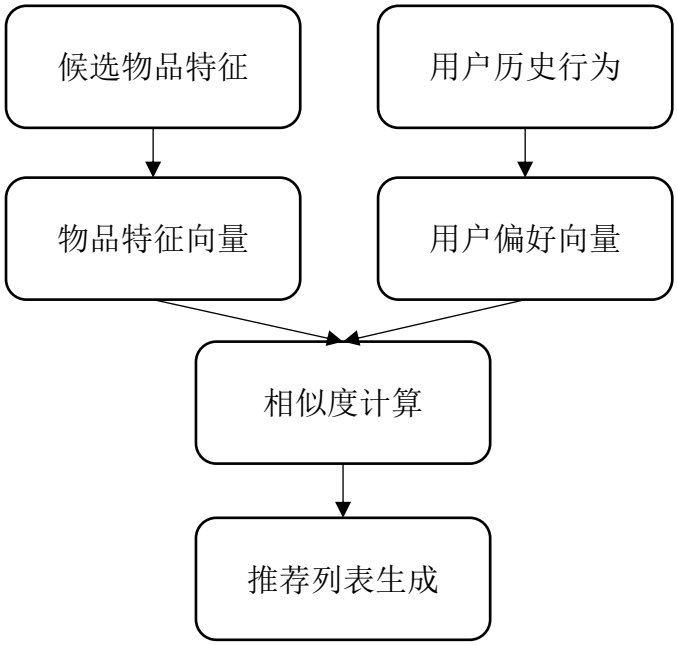

图 2-1 基于内容的推荐算法

Figure 2-1 Content based recommendation algorithm

2.1.2 协同过滤推荐算法

协同过滤推荐算法主要分为基于用户的协同过滤推荐和基于项目的协同过滤推荐两种。它们分别主要用于挖掘用户与用户之间、项目与项目之间的关联规则，根据获得的关联规则进行推荐[19]。

基于用户的协同过滤推荐算法基本原理：假设用户 A 对项目 a、项目 b 有兴趣，用户 B 对项目 c、项目 d 有兴趣，用户 c 对项目 a、项目 b、项目 c 有兴趣，那么可以得出用户 A 和用户 C 有着相近兴趣爱好的结论，从而将用户 C 感兴趣的而用户 A 没有接触过的项目 c 推荐给用户 A，算法如图 2-2 所示。

中国知网 https://www.cnki.net

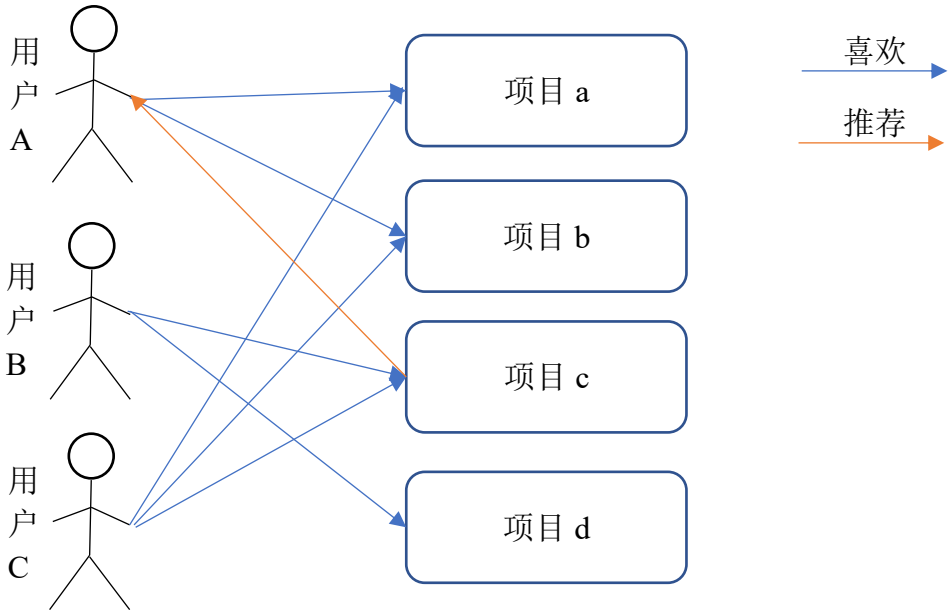

图 2-2 基于用户的协同过滤推荐算法

Figure 2-2 User based collaborative filtering Recommendation Algorithm

基于项目的协同过滤推荐算法：假设用户 A 对项目 a、项目 b、项目 c 感兴趣，用户 B 对项目 b 感兴趣，用户 C 对项目 a、项目 b 感兴趣，可以认为项目 a 和项目 b 的特征相似，从而将用户 B 没有接触过的项目 a 推荐给用户 B，算法如图 2-3 所示。

中国知网 https://www.cnki.net

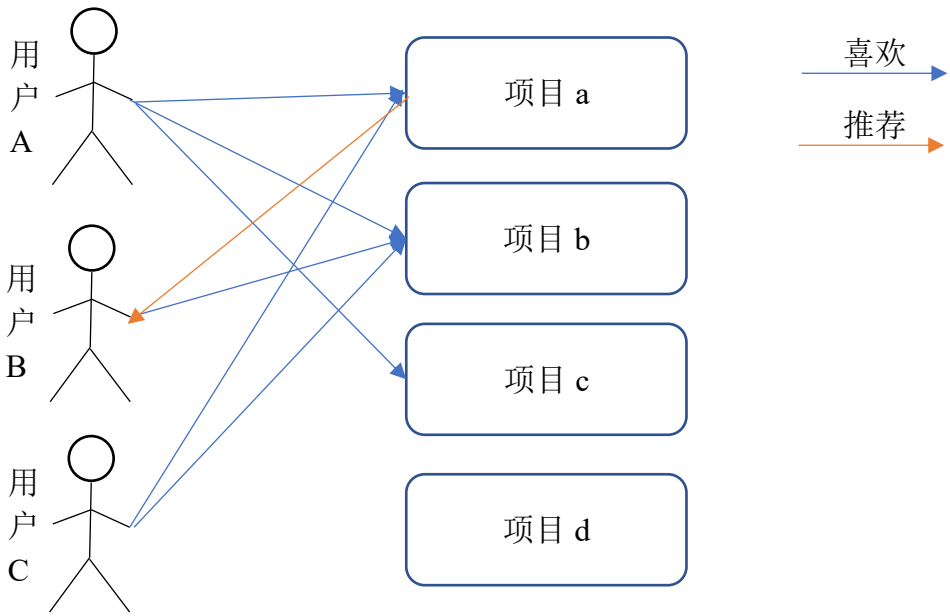

图 2-3 基于项目的协同过滤推荐算法

Figure 2-3 Project based collaborative filtering recommendation algorithm

2.1.3 基于深度学习的推荐算法

近年来，由于传统的协同过滤推荐算法自身存在的缺陷以及数据量指数式的增长，导致其越来越无法满足用户的需求。很多新音乐缺少标签和评分，难以通过推荐算法进入大众的视野，这时可以通过对音乐的频谱以及音频时间序列进行特征提取、分类。而传统的推荐算法无法有效处理图片和音频序列信息，因此难以对新歌曲进行分类[19]。

人工神经网络自从 1943 年由心理学家 W.S.McCulloch 和数理逻辑学家 W.Pitts 提出发展至今，已经成熟运用到各个领域，不仅仅是图像、NLP 领域，在推荐领域也有十分广泛的应用背景。

其原理便是通过训练集对神经网络进行训练，不断优化权重矩阵参数，最终根据模型输出预测。在推荐算法领域有基于卷积神经网络的推荐、基于降噪自动编码器的推荐、基于受限玻尔兹曼机的推荐等[18]。

本文的特征提取模型和推荐模型均使用了深度学习模型。特征提取模型是结合了全卷积神经网络和循环神经网络。推荐模型是使用由基于标签的推荐与基于降噪自动编码器的推荐组成的混合推荐模型，基于标签的推荐就是基于内容的推荐的其中一种。

中国知网 https://www.cnki.net

2.1.3.1 自动编码器

自动编码器（AutoEncoder,AE）,属于非监督学习神经网络,包含了自动编码和自动解码的部分,由输入层、隐藏层、输出层三层网络结构组成.从输入层到隐藏层属于编码部分,隐藏层到输出层属于编码部分.输入层的神经元个数等于输出层的神经元个数,也要大于隐藏层的神经元个数,这种神经元配比可以将输入数据降维,更有利于特征提取.

自动编码器在运行时分为两个阶段:正向传播和反向传播.

正向传播时,设输入样本为$x \in D_k$,输入层和输出层n个神经元,隐藏层m个神经元,从输入层到隐藏层表示如公式(2-1)所示

$$h(x) = \sigma_1(\omega_1 x + b_1) \tag{2-1}$$

其中,ω_1表示输入层和隐藏层间的权重矩阵,阶数为$m \times n$,b_1为偏置项,阶数为$m \times 1$,σ_1表示激活函数,一般选择 Sigmoid、Tanh 或者 Relu 函数.过程体现为将输入进行编码.

从隐藏层到输出层表示如公式(2-2)所示

$$O(h(x)) = \sigma_2(\omega_2 h(x) + b_2) \tag{2-2}$$

其中,ω_2表示隐藏层和输出层间的权重矩阵,阶数为$n \times m$,b_2为偏置项,阶数为$n \times 1$,σ_2表示激活函数,这个过程可以体现为将之前的操作解码,获取特征向量.

至此,前向传播过程已经完成,之后通过计算损失函数,用随机梯度下降法来更新权重矩阵ω_1、ω_2和偏执向量b_1、b_2.损失函数定义如公式(2-3)所示:

$$loss(O(h(x)), x) = \frac{\lambda_1}{2}\sum_{i=1}^{k}\|O(h(x)) - x\|^2 + \frac{\lambda_2}{2}\|\omega_1\| + \frac{\lambda_2}{2}\|\omega_2\| \tag{2-3}$$

其中,$\|\bullet\|$表示矩阵的 2 范数,$\frac{\lambda_2}{2}\|\omega_1\| + \frac{\lambda_2}{2}\|\omega_2\|$是为了防止模型过拟合而加入的正则项,$\lambda_1$、$\lambda_2$一般表示取 0-1 之间.

2.1.3.2 降噪自动编码器

降噪自动编码器是在自动编码器的基础上,对输入数据加入一定的噪声.这种办法有效提升网络的泛化性和鲁棒性,即使在存在噪声的情况下依然能够更加准确的推荐,其余过程包括正向传播和反向传播都和普通的自动编码器一致.本文通过随机选取少量的样本,使其输入值加一,流程如图 2-4 所示.

中国知网 https://www.cnki.net

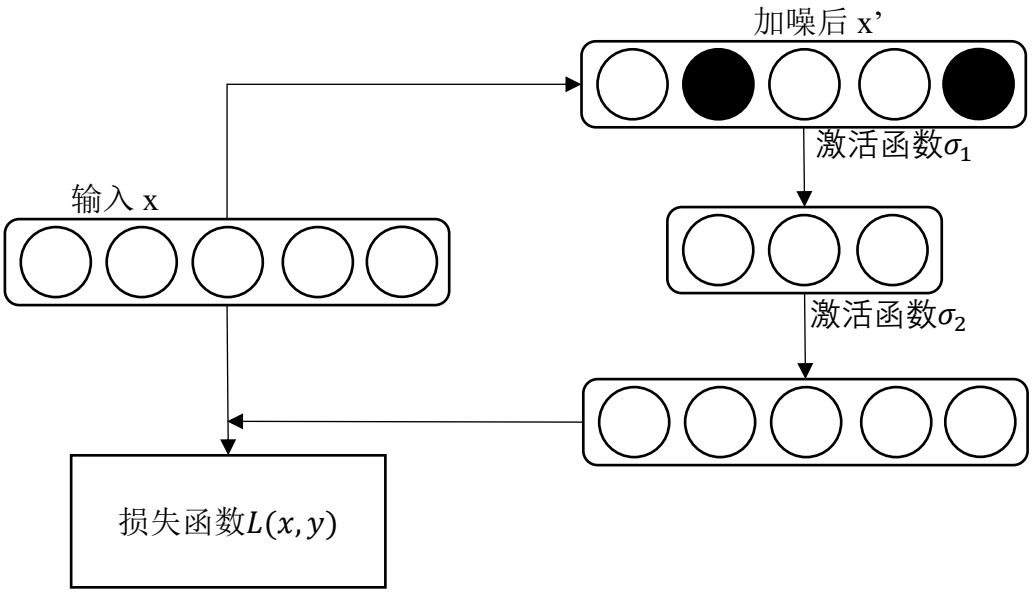

图 2-4 降噪自动编码器流程图

Figure 2-4 Flow Chart of Noise Reduction Automatic Encoder

本文实验结果为基于用户的兴趣爱好,在用户没有评分的项目中生成 Top-N 推荐列表,基于 User-Item 评分表训练网络参数,为避免数据稀疏问题,可以训练两个编码器分别用于用户和项目，激活函数选择 tanh 函数，见公式(2-4):

$$tanh(x) = \frac{e^x - e^x}{e^x + e^x} \tag{2-4}$$

网络结构如图 2-5 所示:

中国知网 https://www.cnki.net

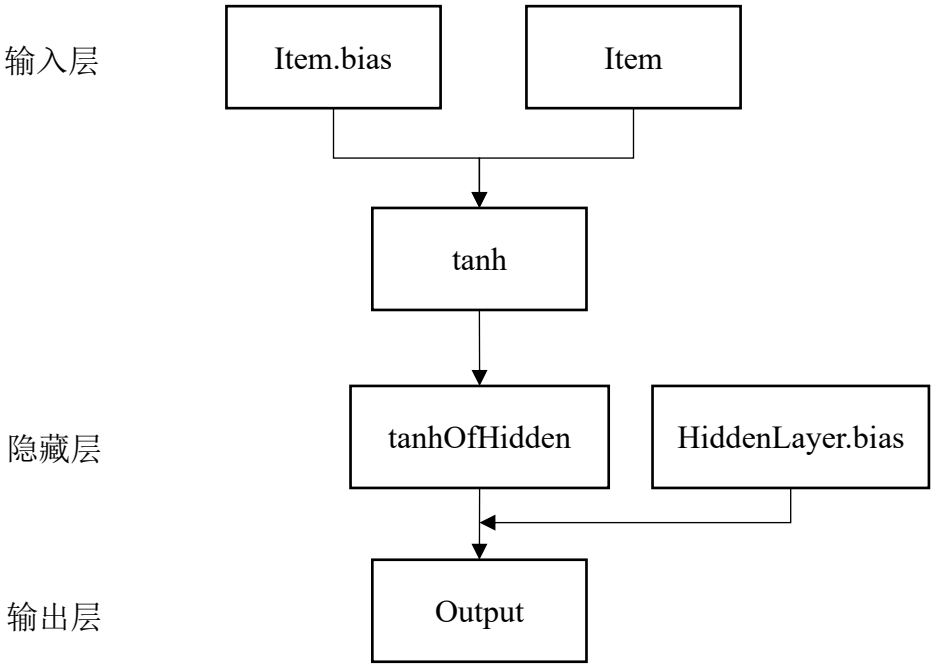

图 2-5 降噪自动编码器网络结构图

Figure 2-5 Network structure diagram of noise reduction automatic encoder

降噪自动编码器使用 Pytorch1.11.0 版本构建.样本$x \in D'_k$,D'_k表示总共有k组经过随机加噪后的数据,训练时,输入$x_i, i \in (0, k)$,即一组用户评分向量,User-Item 评分矩阵中的每一行数据.经过公式（2-1）和公式（2-2）进行正向传播得到当前输出$O(h(x))$,接着根据公式（2-3）计算当前输出和输入之间的损失函数$loss(O(h(x)), x)$,最后对损失函数求偏导进行微调完成梯度下降.通过循环将样本中的所有x_i输入训练网络,至此完成一次训练.

算法伪代码如表 2-1 所示:

表 2-1 算法伪代码

Table2-1 Algorithm pseudo code

Algorithm: Train-network (assuming DAENetwork is implemented)

Input: rating matrix R
For each iteration step:
  Epoch = row Count(R)
  For each epoch in Epoch:
  Output = DAE Network(R)
  Total Loss = Loss(Output)
  Fix Total Loss

中国知网 https://www.cnki.net

经过训练网络步骤后,根据网络输出的新的 User-Item 评分矩阵,运用传统协同过滤方法,通过计算项目之间修正的余弦相似度计算来获得项目的相似度,修正后的余弦相似度输出值范围为[-1,1],负值表示负相关,正值表示正相关,0 代表不相关.修正余弦相似度公式见公式(2-5):

$$sim(x,y)=\frac{\sum_{i\in I_{xy}}(R_{x,i}-\bar{R}_x)(R_{y,i}-\bar{R}_y)}{\sqrt{\sum_{i\in I_{xy}}(R_{x,i}-\bar{R}_x)^2}\sqrt{\sum_{i\in I_{xy}}(R_{y,i}-\bar{R}_y)^2}} \tag{2-5}$$

其中,$sim(x,y)$表示用户x和用户y之间的修正余弦相似度,I_{xy}表示用户x和用户y评分过的项目的并集,$R_{x,i}$、$R_{y,i}$分别表示用户x或用户y对项目i的评分,$\bar{R}_x$、$\bar{R}_y$分别表示用户x或用户y对项目评分的平均值.

此外，对于新用户而言，由于缺乏评分矩阵无法训练数据，还需要加入基于音乐属性标签的推荐算法，包含前文所提到的通过大数据分析获得的标签、通过 FCGRNN 提取的音频特征属性标签以及数据集中自带的标签属性。

2.1.3.3 卷积神经网络

卷积神经网络主要分为输入层、卷积层、池化层、全连接层、输出层。卷积层的作用是降低数据的维度，池化层的作用是在尽可能地保留输入数据的主要特征的同时进一步压缩数据量和参数量。标准的 CNN 结构如图 3-8 所示。

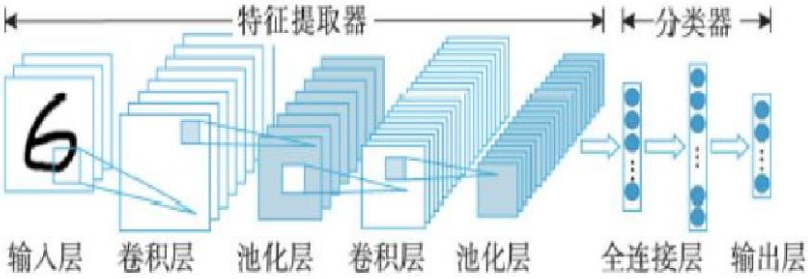

图 2-6 卷积神经网络结构

Figure 2-6 Convolutional Neural Network Structure

图像先通过函数编程平铺的一维数据输入网络，经过卷积、池化等操作，最后通过全连接层或者 softmax 进行分类输出。本文提出的模型中卷积神经网络模块为全卷积网络(FCN)。将获得的梅尔频谱图输入全卷积网络进行特性提取，不断地经过卷积池化操作，提取出相关特征，交由输出层的 softmax 分类器输出结果，不断迭代训练好网络参数，保存至本地。

中国知网 https://www.cnki.net

2.1.3.4 循环神经网络

卷积神经网络处理数据时往往会忽略数据中的时间序列相关性，而音乐频谱包含了大量的上下文内容，此时需要用循环神经网络处理更不容易丢失相关性，循环神经神经网络具有记忆性、参数共享特点。记忆性指的是短期记忆。参数共享指的是在某一个时间步上，所对应的参数是共享的。循环神经网络的网络结构如图 2-7 所示，I 为输入层，H 为隐藏层，O 为输出层，W 为权重矩阵。可以看出第二个时间步时隐藏层的输入不仅仅取决于输入层，还和权重矩阵相关。

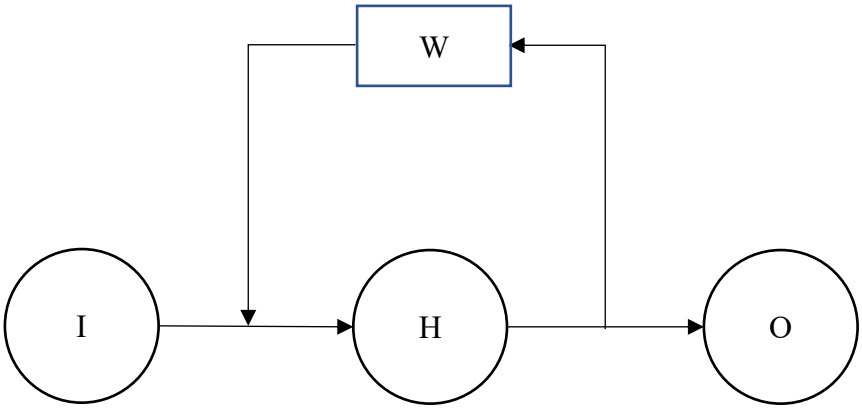

图 2-7 RNN 基本结构

Figure 2-7 Basic Structure of RNN

音乐频谱的特征提取不能忽略上下文的相关性，因此本文的特征提取模型需要加入循环神经网络获取梅尔频谱深层次的特征

2.2 衡量推荐算法性能的指标

均方误差和召回率是作为衡量推荐系统的主要指标。

均方根误差（RMSE）是对基于神经网络的推荐算法的预测值与实际值之间的误差先求平方和，再去平均数，最后开根号。RMSE 越小越好，其计算公式见公式(2-6)：

$$RMSE = \sqrt{\frac{\sum_{R_{ij},\hat{R}_{ij}\in R}(R_{ij}-\hat{R}_{ij})}{n}} \tag{2-6}$$

中国知网 https://www.cnki.net

召回率（Recall）则表示生成的 Top-N 推荐列表中的项目确实为用户评分过的项目的概率。Recall 越大越好，其计算公式见公式(2-7)：

$$recall = \frac{|T \cap S|}{|S|} \tag{2-7}$$

2.3 Springboot 框架

Springboot 框架是由 Pivotal 团队提供的全新框架，基于 Java 编程语言开发，其前身是 Spring 框架。以往基于 Spring、SpringMVC、Mybatis 开发的项目，开发初期便有繁杂的配置文件，因此导致开发人员大量时间花费在配置文件上，无法专注于开发工作。而 Springboot 是一个一站式的开发框架，它不仅具有控制反转和面向切面编程的特点，而且开还具有箱即用和约定大于配置是两大重要特性，其自动配置的设计也是它能够从众多开发框架中脱颖而出主要原因，其使得其他各框架之间的配置文件得以简化，在开发时只需关注核心业务代码，极大提高了便利性[21]，启动流程如图 2-8 所示。

中国知网 https://www.cnki.net

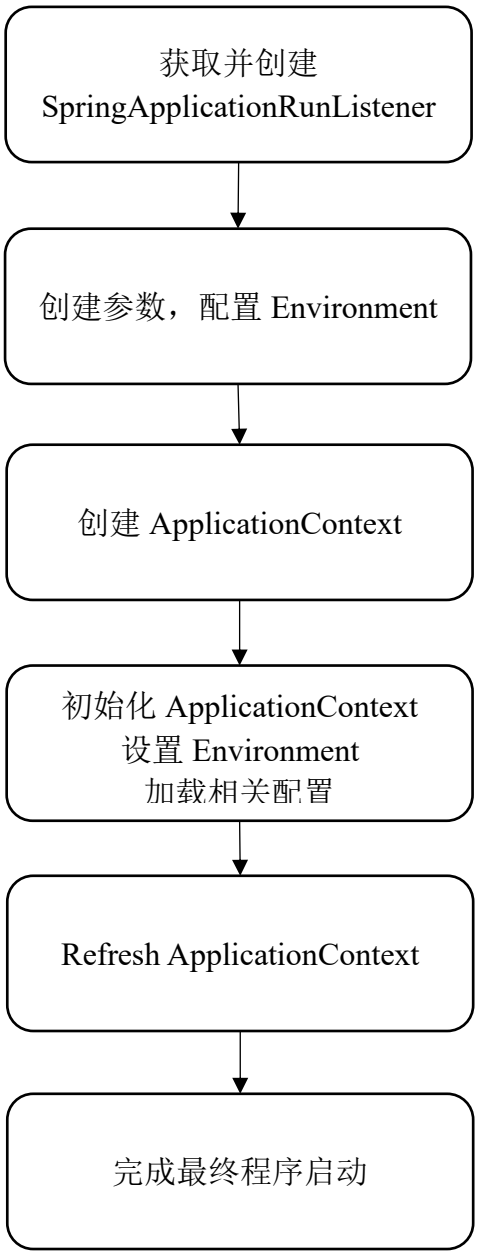

图 2-8Springboot 启动流程图

Figure 2-8 Springboot startup flowchar

2.3.1 Spring Boot 的优势

Springboot 是基于 Spring4.0 设计产生的，它在具有所有 Spring 框架原有的

中国知网 https://www.cnki.net

优势同时，还进一步简化了 Spring 类项目的开发设计。它在配置简单的条件下还能快速的启动一个企业级项目，极大地提高了开发效率。开发时可以使用 maven 命令行语言配置来导入所需要的 jar 包，maven 优先从本地仓库查找并导入，如果本地找不到则会进入配置好的源网站下载。项目自带 tomcat 服务器，部署发布时只需打包成 jar 就部署，同时也具备有热部署功能，在开发和维护上面都具有很大的优势。在常规的 SSM 模型下，各个子模块都有 starter 启动类，每个模块会自动生成 application.yaml 配置文件，配置文件内规定了项目运行时的各种参数以及所需 jar 包的版本。自动配置的设计，简化了框架之间的配置，仅需修改对应的参数值就能完成配置，不需要繁琐配置各种 XML 文件，开箱即用。Springboot 也支持 restful 编程，多个 Springboot 集成的 SpringCloud 在微服务开发上也有着非常广泛的应用，而且能够兼容各种数据库。

2.3.2 Springboot 的自动配置原理

Springboot 在启动时先加载带有@SpringBootApplication 注解的类，也称启动类，@EnableAutoConfiguration 注解里可以自定义是否开启开启自动配置功能，它的作用是将主配置类所在包及其下属所有子包内的所有组件扫描至 Spring 的 Bean 容器中，这个注解是一个组合注解，其下包括一个重要注解，组件选择器@AutoConfigurationImportSelector，这个注解的主要功能是向 Bean 容器中导入相关的组件，返回一个包含了所需所有组件的全限定名的列表，筛选通过后这些组件就会添加进容器中，再通过返回的类名向容器中导入相关的配置类 [23]。每一个这样 AutoConfiguration 类都是容器中的一个组件，每一个组件都需要添加进容器中，确保项目完整的运行。

2.4 Mybatis 框架

Mybatis 是一个具有强底层逻辑的、与关系型数据库交互的框架，它有着很多优秀的功能，可以避免 JDBC 的 Sql 注入等问题。Mybatis 框架将重复的操作都集成起来，只需要通过修改注解或者是 XML 配置文件等方式就可以完成从与数据库的交互。其框架组成如图 2-9 所示。

中国知网 https://www.cnki.net

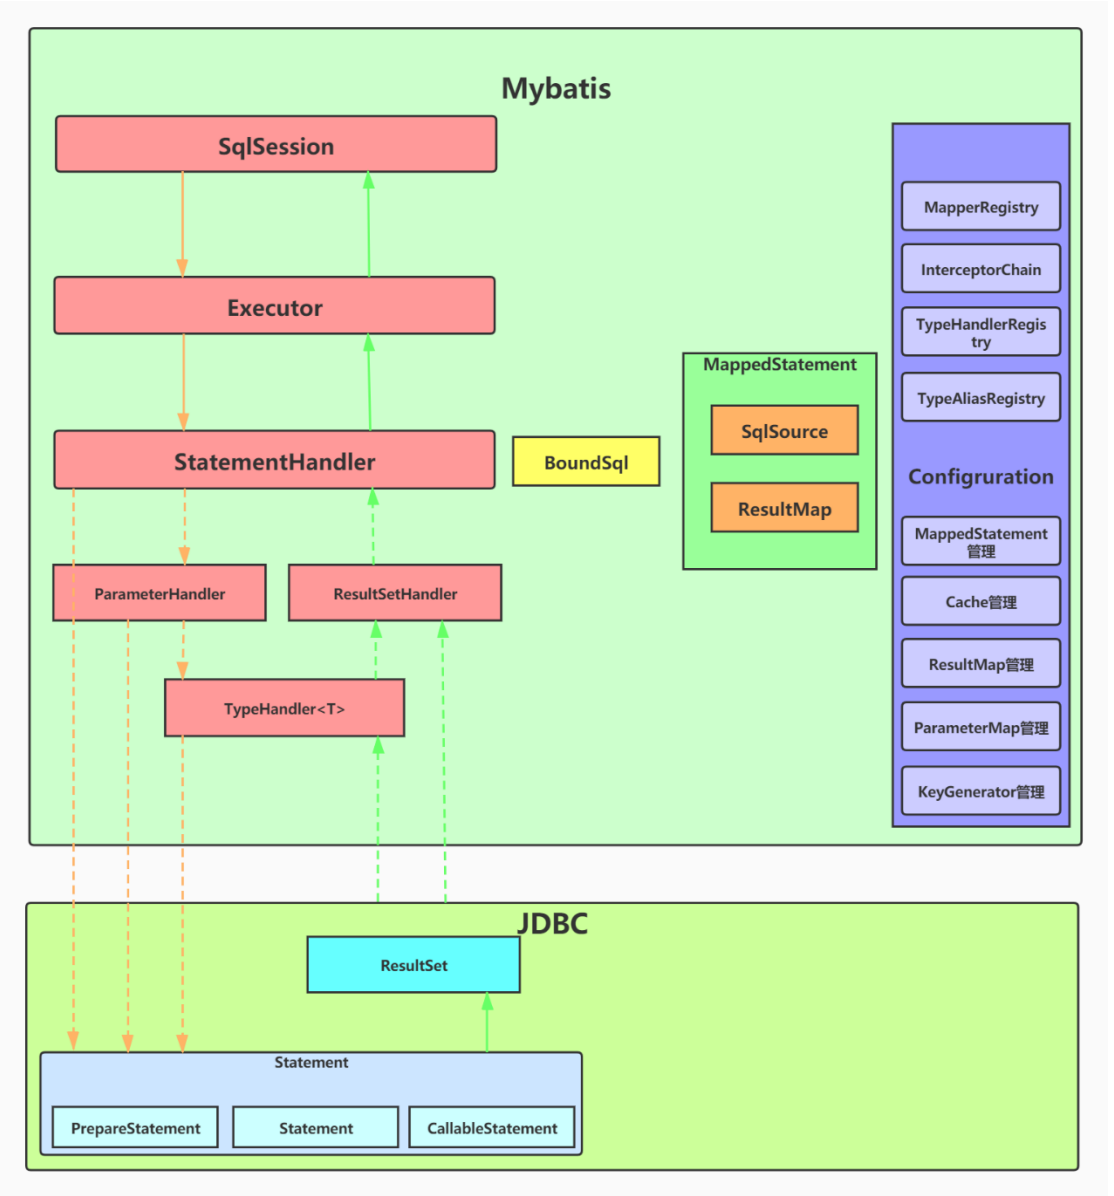

图 2-9 Mybatis 框架组成图

Figure 2-9 Mybatis framework composition diagram

2.4.1 Mybatis 的优势

1.简洁易用：作为一个持久层框架，具有高轻量级的优点；使用时不需要其他依赖，只需通过修改注解类或者 XML 配置文件就能完成一次持久层访问。

2.灵活：通过修改注解或者 XML 配置文件的方式访问数据库，便于阅读且

中国知网 https://www.cnki.net

修改起来灵活。

3.解耦：将业务层逻辑与 sql 语句进行分离，有效防止 sql 注入导致的数据泄漏问题，使得系统开发更加简便、逻辑更加清晰。

4.减少冗余：访问数据库时框架自带模板，开发人员只需写好 sql 语句。

5.通过注解可以优化 sql 语句，返回的数据可以直接被 JVM 封装成对象。

6.有注解配置和 XML 配置文件两种配置方式，给开发人员带来了极大的便利。

2.4.2 Mybatis 的运行流程

1.加载配置：加载配置时主要通过两种方式，一种是基于 XML 配置文件，通过读取 XML 配置文件中的标签值传递参数；另一种是通过@Mapper 注解配置，读取被注解标记的类，再传入相关的参数。

2.sql 解析： Mybatis 会进行内部解析，获得即将被执行的 sql 语句。

3.sql 执行：通过 Executor 执行解析出的 sql，并返回 sql 结果。

4.结果映射：将返回的结果映射成约定的类型，并返回对象结果。

Mybatis 流程图如图 2-10 所示。

中国知网 https://www.cnki.net

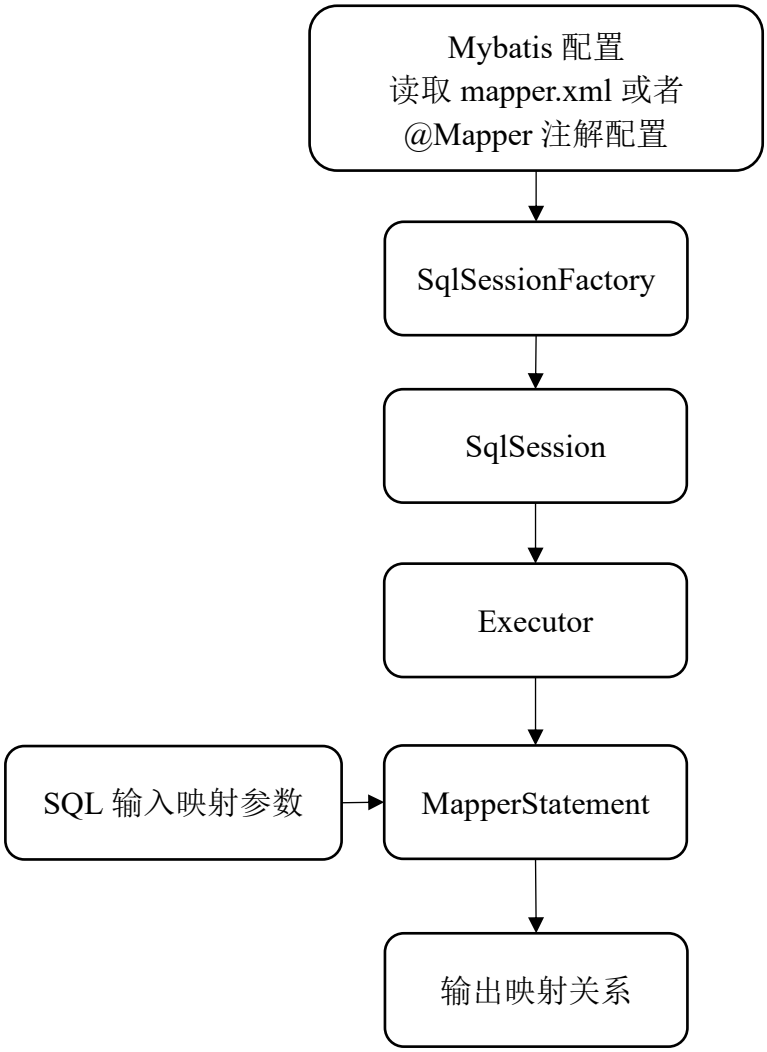

图 2-10 Mybatis 流程图

Figure 2-10 Mybatis flowchart

2.5 模板引擎 Thymeleaf

Thymeleaf 可以实现逻辑和页面的分离，能够兼容 Springboot，能对数据进行动态渲染。在 web 端开发中，动态数据通过标签渲染进由 Thymeleaf 提供的页面模板中，编译的时候会自动将标签转换成需要渲染的数据，在可以在浏览器上渲染出预期效果。Thymeleaf 简单易用，使用时只需要导入相应版本的 jar 包即可。而且全版本开源，社区用户活跃，对于使用时常见的问题，在 CSDN 或者 stackoverflow 社区都能够找到对应的解决方案。渲染页面时不用 HTML、

中国知网 https://www.cnki.net

CSS 的原因是模板引擎可以实现代码逻辑和页面显示的分离，模板引擎原理如图 2-11 所示：

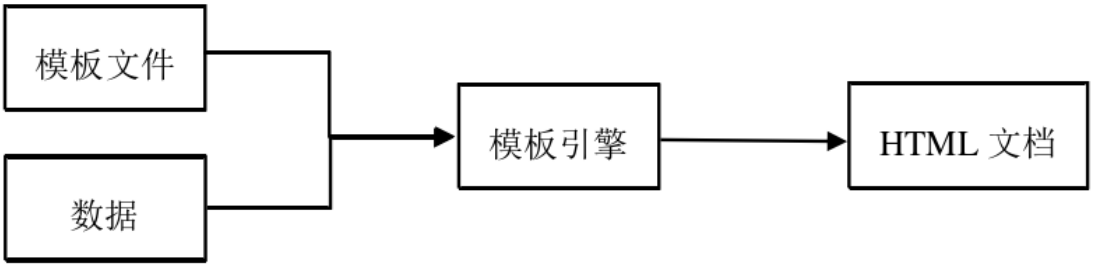

图 2-11 模板引擎图

Figure 2-11 Template Engine Diagram

2.5.1 Thymeleaf 的特点

1.页面显示与代码逻辑分离：可以使静态页面和代码分离，只需在静态页面中添加相关的标签，就可以在解析时将需要渲染数据替换掉原来的标签。

2.简单易用。使用时与 HTML 区别不大，并且在使用的时候只需要通过 maven 导入相应版本的 jar 包，然后在模板文件的头文件进行声明即可。

3.兼容性好：不仅兼容后端框架 Springboot，也能搭配例如 Vue 等前端框架一起使用，可以极大的提高开发效率。

2.6 MySQL

MySQL 是一个专业的数据库软件，专门用来持久化数据，具有多种的存储引擎。同时 MySQL 也具有全版本开源、社区用户活跃等特点，官方提供学习文档，查找和修改的速度比其他数据库更快。目前各种各样的小型企业级项目和应用都选择 MySQL，开源对于中小型公司特别友好，因此在规模较小的企业项目或者科研实验用时一般采用 MySQL 作为关系型数据库。它提供的功能齐全，命令行界面优秀，并且执行 sql 语句的效率很高，因此本系统在开发时也是采用 MySQL 作为关系型数据库。

2.6.1 MySQL 特点

下面总结了一些 MySQL 的特点：

1.功能强大：不仅常规功能齐全，还拥有多种类的存储引擎，无论是企业用

中国知网 https://www.cnki.net

还是科研用都能够满足要求。

2.跨平台性：MySQL 可以在多种操作系统上运行，包括 Windows、Linux、macOS 等，支持跨平台的应用部署。

3.运行速度快：在 MySQL 中，索引的数据结构是 B+树，B+树比较与顺序的查找和修改的时间复杂度和空间复杂度都很低，而索引的建立后是从索引的根节点开始进行查找。执行 SQL 语句的效率极高。

4.支持面向对象：在通过 JDBC 访问 MySQL 数据库时可以直接封装成 Java 对象返回结果。

5.安全性高：数据库具有多重加密功能，登录数据库时需要验证密码，增、删、改、查等操作时也需要数据库所有者给予权限才能进行下一步操作。

6.成本低：MySQL 是开源免费的，科研用十分方便。

7.可对接多种语言：为 Java、Python、PHP、C++、Perl、ASP.NET、Eiffel、Ruby、Tcl、C 语言等编程语言提供了 API 接口。

8.存储容量大：MySQL 属于关系型数据库，相较于顺序存储可以节约大量空间。

2.6.2 MySQL 数据库存储引擎

MySQL 主要有 MyISAM 和 InnoDB 两种存储引擎。MyISAM 与 InnoDB 有以下主要区别：

1.事务支持：InnoDB 是一种支持事务的存储引擎，可以处理具有事务需求的应用程序，例如需要回滚和提交的复杂数据库操作。而 MyISAM 不支持事务，这意味着在 MyISAM 表上执行的操作不会被回滚，可能会导致数据不一致。

2.锁级别：InnoDB 支持行级锁，这意味着在对表进行读写操作时，只锁定需要的行，而不是锁定整个表，从而提供更好的并发性能。而 MyISAM 只支持表级锁，这意味着在对表进行读写操作时，会锁定整个表，可能导致并发性能较差。

3.数据完整性：InnoDB 支持外键约束和事务日志（或称为 redo log），可以保持数据的完整性和一致性，从而提供更高的数据安全性。而 MyISAM 不支持外键约束和事务日志，因此在需要强制数据完整性的应用中，InnoDB 更为适合。

4.性能特点：MyISAM 在读取大量静态数据时具有较好的性能，而 InnoDB 在处理大量并发读写操作时表现较好。此外，InnoDB 支持缓冲池（buffer pool）来缓存数据和索引，从而提供更好的性能。

5.备份和恢复：MyISAM 表的备份和恢复相对简单，可以通过直接复制表文件来完成。而 InnoDB 表的备份和恢复需要使用 MySQL 的专用工具或者进行逐表导出和导入。

中国知网 https://www.cnki.net

6.全文搜索：MyISAM 表支持 MySQL 的全文搜索功能，而 InnoDB 表在 MySQL 5.6 版本之前不支持全文搜索。

7.可用性：InnoDB 表支持热备份和崩溃恢复，可以在系统崩溃后更好地保护数据的完整性。而 MyISAM 表不支持热备份和崩溃恢复，可能在系统崩溃时导致数据丢失或损坏。

2.7 本章小结

本章分析了协同过滤推荐算法、基于深度学习推荐算法基本原理，简要介绍了衡量推荐算法的几个指标及相关系数的计算方法，详细介绍了系统 Web 端开发的基础知识，音乐推荐系统设计与实现基于这些理论基础得以实现。

中国知网 https://www.cnki.net

第 3 章 音乐推荐系统模型

本章介绍基于深度学习的推荐系统模型，包括通过全卷积网络与循环神经网络提取音乐图谱特征的特征提取模型，以及混合基于降噪自动编码器的协同过滤推荐算法和基于标签推荐的推荐模型。此模型是多种神经网络协同进行推荐，能更准确地发现音乐与音乐之间的隐含特征，从而更好地解决音乐推荐系统的常见问题。本文提出的推荐系统流程图如图 3-1 所示。

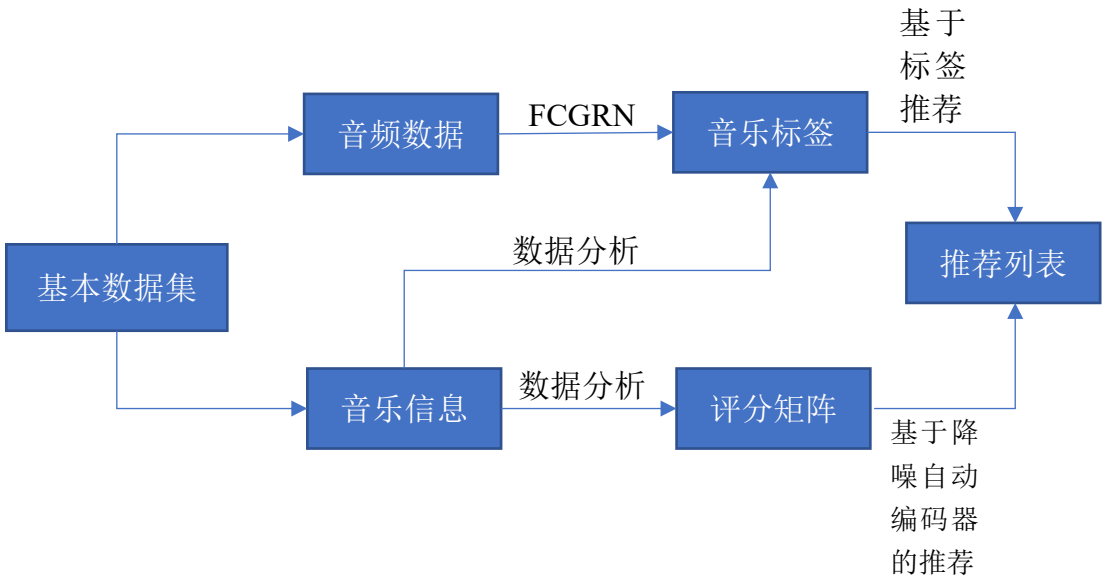

图 3-1 推荐系统流程图

Figure 3-1 Recommendation System Flowchart

3.1 当下音乐推荐系统的常见问题

协同过滤推荐算法和深度学习经过多年的发展，已经在各自领域有了深层次的应用。但是由于缺少习惯对音乐进行评分的用户，音乐的评分矩阵往往稀疏性较高[28]。而这种稀疏性对于使用神经网络结构的深度学习方法影响不大。单一的卷积神经网络在提取音乐频谱特征时容易忽视音乐的前后时间特性，结合具有长短时记忆的循环神经网络能够弥补这方面的不足。根据音乐的语种、风格等特点将其划分为不同的类型，因此从本质上来说对音乐频谱的特征提取工作就是分类问题。

中国知网 https://www.cnki.net

同时对于音乐推荐系统来说，存在下列常见问题：

1.音乐场景维度下的推荐问题。根据用户 A、B 的偏好矩阵构建协同过滤推荐模型，通过此模型对用户 C 进行音乐推荐，通常情况下这种推荐方法会有很高的精准度。

但是在某些情景中会起反作用，考虑到人类在深夜往往更倾向于听符合情感需求的歌曲，此时与日常的倾听习惯关系不大，例如用户 A、用户 B 日常习惯倾听摇滚类型的歌曲，但是深夜时更愿意倾听民谣释放情绪，这是再通过模型很可能会给用户 C 在深夜推荐给摇滚乐，这种情况推荐效果就比较差[25]。

2.音乐标签缺失问题。大多是热门歌曲或者音乐数据集会有标签，但是其中的标签大多仅仅属于音乐风格类型的标签，例如“摇滚”、“华语”、“粤语”等。但是为了更好的解决前面所说的问题，需要的是音乐播放在不同时间段播放次数的标签也尤为重要。

此时不仅仅需要利用卷积神经网络和循环神经网络对音乐频谱进行特征提取，还需要进行大数据分析，补全音乐标签[26]。

3.2 数据集与特征工程

目前可以公开获取的音乐数据集主要有 Million Song Dataset、Last.fm、MSD's Last.fm 等。Million Song Dataset 是由 Columbia University 和 The Echo Nest 共同创建的一个大规模音乐数据集，包含百万级别的音乐文件、歌曲元数据、歌词、歌手信息等。虽然 MSD 是一个大规模音乐数据集但是数据不全面，尽管名字中包含"百万歌曲"，但 MSD 并不包含所有的音乐作品，它只包含了一百万首歌曲的数据，而且大部分数据集中在 20 世纪的音乐作品，对于近年来的音乐作品可能覆盖不足，而且缺乏音乐特征，MSD 主要包含了音乐的元数据信息，如歌曲的歌手、专辑、发行年份等，但对于音乐的音乐特征，如音调、节奏、情感等，数据较为有限。这限制了在音乐特征分析和音乐推荐等任务中的应用。。鉴于以上公开数据集所存在的问题，本文通过爬取网易云音乐的公开数据，如音乐信息、歌手信息、专辑信息、用户评论、歌单等，自行构建音乐数据集。

3.2.1 数据来源

本文选择通过前端 JavaScript 脚本以及 Vue3.0 框架访问 Github 上网易云公开的 API——NeteaseCloudMusicApi。

通过 Vue3.0 框架向 NeteaseCloudMusicApi 发起请求，后者会返回相应的 JSON 格式的数据，对这些数据进行处理以构建所需要的数据集[29]。

中国知网 https://www.cnki.net

数据集统计详情如表 3-1 所示。

表 3-1 数据集统计

Table 3-1 Dataset Statistics

数据项	数量（条）	备注
音乐	25469	音乐信息及音频链接
音乐标签	74834	音乐所属标签
用户	800	用户信息
用户标签	2850	用户所属标签
歌手	11700	歌手信息
歌手标签	35730	歌手所属标签
歌单	960	歌单基本信息
历史记录	100000	用户对单首音乐的重复收听次数

数据集中的音乐通过语种、风格、场景、情感、主题等 5 个方面进行分类。每个分类指标如表 3-2 所示。

表 3-2 音乐分类

Table 3-2 Music Classification

分类指标	详情分类
语种	华语、粤语、英语、西班牙语、日语、韩语等
情感	怀旧、清新、浪漫、痛苦、治愈、孤独等
风格	流行、古风、草原、爵士、乡村、轻音乐等
主题	综艺、ACG、儿童、游戏、80 后、90 后等
场景	清晨、夜晚、学习、工作、下午茶、打篮球等

音乐分类中的标签不全是是按照音乐特征来划分的，有的是通过大数据分析或者人为划分。

3.2.2 建立用户评分矩阵

NeteaseCloudMusicApi 返回的 JSON 结果中没有用户对音乐的直接评分数据，因此需要通过分析数据中的隐式规则构建用户评分矩阵。

根据用户的播放历史记录中的音乐重复播放次数，可以推断出用户对音乐的喜好程度。这是因为用户在重复播放一首歌曲时，通常是因为他们喜欢这首歌曲，或者这首歌曲给他们带来了某种特殊的情感体验。

中国知网 https://www.cnki.net

表 3-3 用户的播放次数

Table 3-3 User Playback Times

	音乐M_1	音乐M_2	音乐M_3	音乐M_4	音乐M_5
用户U_1	N_{11}	N_{12}	N_{13}	N_{14}	N_{15}

用户U_1的播放历史记录中的各个音乐播放次数表 3-3 所示，假设N_{11}为最大值，利用该用户播放历史次数建立用户-音乐的评分矩阵，算法描述如下。

1.对用户播放历史记录中所有音乐播放次数进行均值归一化处理，计算方法为音乐播放次数与最大播放次数的商，那么归化操作为$n_{11} = N_{11}/N_{11} = 1$，$n_{12} = N_{12}/N_{11}$，以此类推；

2.将n_{ij}乘以 10 并舍弃小数部分，获得用户对播放历史记录中所有音乐的相对播放次数。这样用户对所有音乐的播放次数均在 0 到 10 之间，其中 0 表示从未收听过的音乐，10 表示最大播放次数的音乐，最终获得用户评分向量；

3.用户评分矩阵中每一行表示单个用户对所有音乐的评分数据，每一列表示所有用户对单首音乐的评分数据。

最终，可以发现根据 NeteaseCloudMusicApi 所获得的数据而生成的用户-音乐评分矩阵为一个稀疏阵。

3.3 特征提取

音频特征提取是指从音频信号中提取有用的特征信息，用于音频信号的分析、处理和应用。音乐的音频特征通常包含时域和频域两种信息，因为音乐信号在时域和频域上都有丰富的特性。同时表达音频的时域和频域信息可以更全面地描述音乐信号的特点，有助于提高音频处理任务的性能。本文研究了能够同时表达音频时域和频域信息的特征表示方法[30]。

音乐的音频文件一般是以 MP3 格式存储的一维时域信号。傅里叶变换将整个信号视为一个静态频谱，无法捕捉到音乐信号在时间上的动态变化。

为了解决这个问题，可以使用一些基于窗口的时频分析方法，例如短时傅里叶变换（Short-Time Fourier Transform, STFT）、连续小波变换（Continuous Wavelet Transform, CWT）、希尔伯特-黄变换（Hilbert-Huang Transform, HHT）等。这些方法将音频信号分成短时窗口，在每个窗口上进行频域分析，可以获得音频信号在不同时间段上的频谱信息，从而更好地捕捉到音乐信号频率随时间变化的特性[34]。

本文采用短时傅里叶将音频信号划分为若干小段，并在每一段上进行傅里叶变换，从而获得该段音频信号在频域上的能量分布。数据集中某一首歌曲在时域上的波形图如图 3-2 所示，横轴是时间轴，纵轴是幅度。

中国知网 https://www.cnki.net

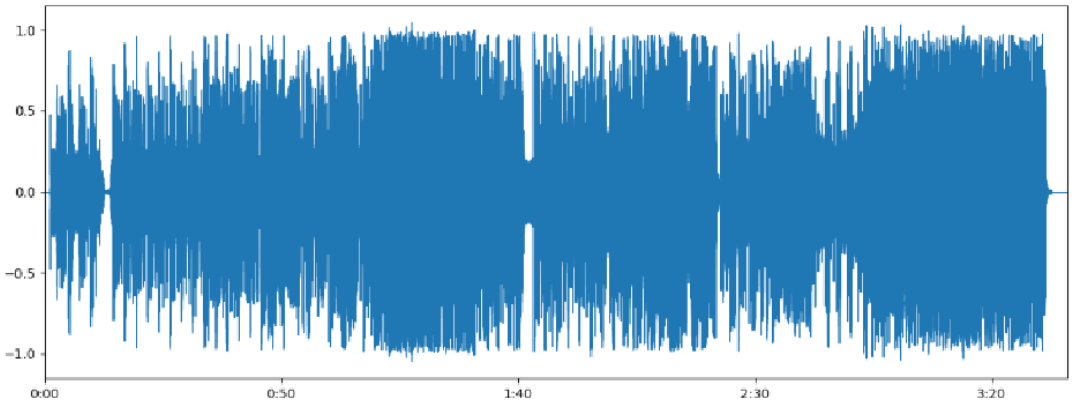

图 3-2 音乐频谱的时域波形

Figure 3-2 Time domain waveform of music spectrum

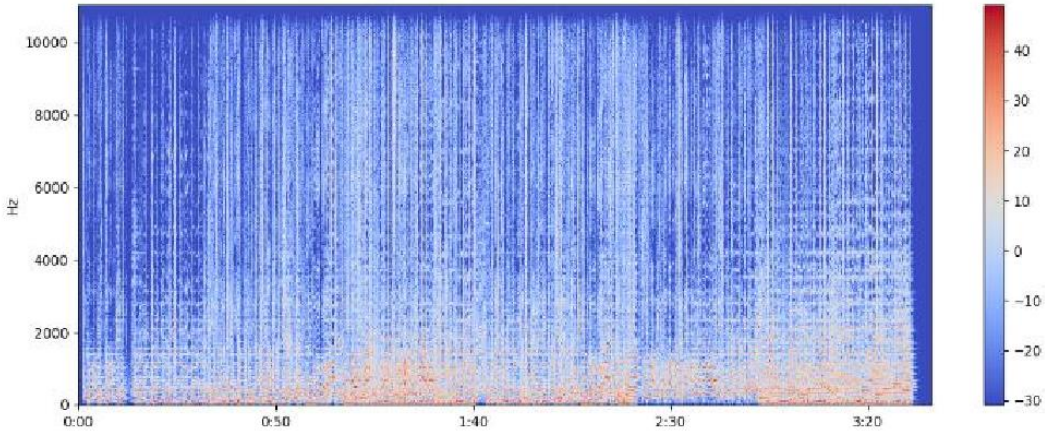

图 3-3 经傅里叶变换后的频域波形

Figure 3-3 Frequency domain waveform of music spectrum after Fourier transform

经短时傅里叶变换得到的音频信号时变频谱图如图 3-3 所示，横轴上的数值表示音频信号在时间上的变化，从左到右表示音频信号的时间演化，可以看作音频信号的时间轴，纵轴表示频率轴，单位通常为赫兹（Hz）。纵轴上的数值表示音频信号在频域上的能量分布，从下到上表示音频信号的频率特征，可以看作音频信号的频率轴[36]。

事实上，人耳对音频频率的感知并不是线性的，而是遵循梅尔频率（Mel scale）或倍音感知等非线性规律。梅尔频率是一种基于人类听觉系统对频率的感知特性而设计的非线性频率刻度。在梅尔频率中，低频区域的频率间隔比高频区域的频率间隔更大，这反映了人耳对低频音调的辨别能力更强。梅尔频率可以通过以下公式(3-1)计算：

$$mel(f) = 2595 \times log_{10}(1 + f/700) \quad (3\text{-}1)$$

中国知网 https://www.cnki.net

通过梅尔映射公式得到的梅尔频率，人类的听觉对梅尔频率的感知为线性的，当音频的梅尔频率提升了一倍，则人耳能感知到音调也提升了一倍[38]。图 3-3 经过公式(3-1)计算后得到的梅尔频谱图如图 3-4 所示。横轴扔然是时间轴，纵轴此时变为梅尔频率。

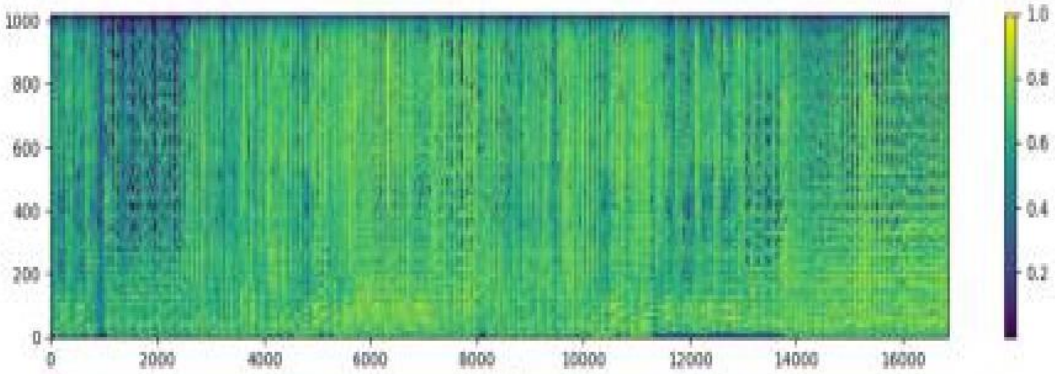

图 3-4 梅尔频谱图

Figure 3-4 Mel spectrum diagram

梅尔频谱作为一种在频率域上的特征表示，能够更好地模拟人耳对不同频率的感知敏感度不同的特性。将梅尔频谱作为输入特征与神经网络结合，可以帮助神经网络更好地理解音频信号的频域信息，并从中学习到更有效的特征表示。这样的特征表示能够更好地捕捉音乐中的情感和认知信息，从而在音乐分类任务中提高分类性能。

Schrauwen 等人在音乐分类标注任务时使用了 D-CNN 模型，通过实验结果证明了基于音乐音频的梅尔频谱图进行分类比使用原始音频图进行分类表现更好[39]。Wang 等人提出了使用卷积层代替全连接层的 FCN 音乐分类模型，具有增加网络深、保留空间信息、减少网络参数等特点[40]。以上音乐分类模型的分类结果都是通过卷积操作得到的。使用卷积神经网络模型来分析音乐音频特征，其主要思想都是将音乐音频转化为图像表示，利用优化的 CNN 来进行特征提取[41]。在传统的卷积操作中，通常是局部感知，即只考虑了局部的特征信息，而没有考虑到全局的时间序列规律。

为了更好地捕捉音乐中的时间序列信息，一些音乐分类模型采用了长短时记忆网络（Long Short-Term Memory, LSTM）或门控循环单元（Gated Recurrent Unit, GRU）等循环神经网络（RNN）结构，这些结构具有记忆性，能够对输入序列中的长期依赖关系进行建模。这样的模型能够更好地捕捉音乐中的时间序列规律，从而提高音乐分类的效果。[45]。本文提出将 RNN 与 FCN 结合，提取音乐音频特征，提高分类效果[47]。

中国知网 https://www.cnki.net

3.3.3 FCGRNN 网络模型结构

全卷积网络相较于普通的卷积神经网络是通过转置卷积层将中间层特征图的高和宽变换回输入图像的尺寸，从而使得预测结果与输入图像在空间维（高和宽）上一一对应：给定空间维上的位置，通道维的输出即该位置对应像素的类别预测。

RNN 是一种递归的神经网络，其在处理序列数据时通过在每个时间步骤上保持隐状态，并将其传递给下一个时间步骤来实现短期记忆。然而，在处理长序列时，RNN 存在一些问题。首先，权重累加极限问题是指在 RNN 中，由于网络的递归结构，随着时间步骤的增加，权重可能会变得非常大或非常小，从而超过浮点数的表示范围，导致数值溢出或下溢。这可能导致网络的输出不稳定，并影响结果的正确性。其次，梯度消失问题是指在 RNN 的训练过程中，梯度可能会随着时间步骤的增加而指数级地变小，从而导致较早时间步骤处的权重更新非常小，无法有效地学习长期依赖关系。这可能导致网络难以捕捉到长期的时间序列模式，从而导致结果失真。为了解决这些问题，一些改进的 RNN 变种已经被引入，例如长短时记忆网络（LSTM）和门控循环单元（GRU），它们具有更复杂的门控机制，可以更好地处理长期依赖关系，并减轻权重累加极限和梯度消失问题。但由于 GRU 只能利用历史信息,Xu 等提出用 BGRU 学习长期音频模式进而利用未来信息;接着,选用 sigmoid 激活函数,通过一个前馈神经层得到目标音频事件的后验概率[48];最后,CGRNN 用单层前馈深度神经网络(deep neural network,DNN)处理 BGRU 的最终序列以预测标签的后验概率。FCGRNN 本文提出的联合 FCN 和 RNN 模型称为 FCGRNN（Full Convolutional Gated Recurrent Neural Network）模型，模型结构如图 3-5 所示。

中国知网 https://www.cnki.net

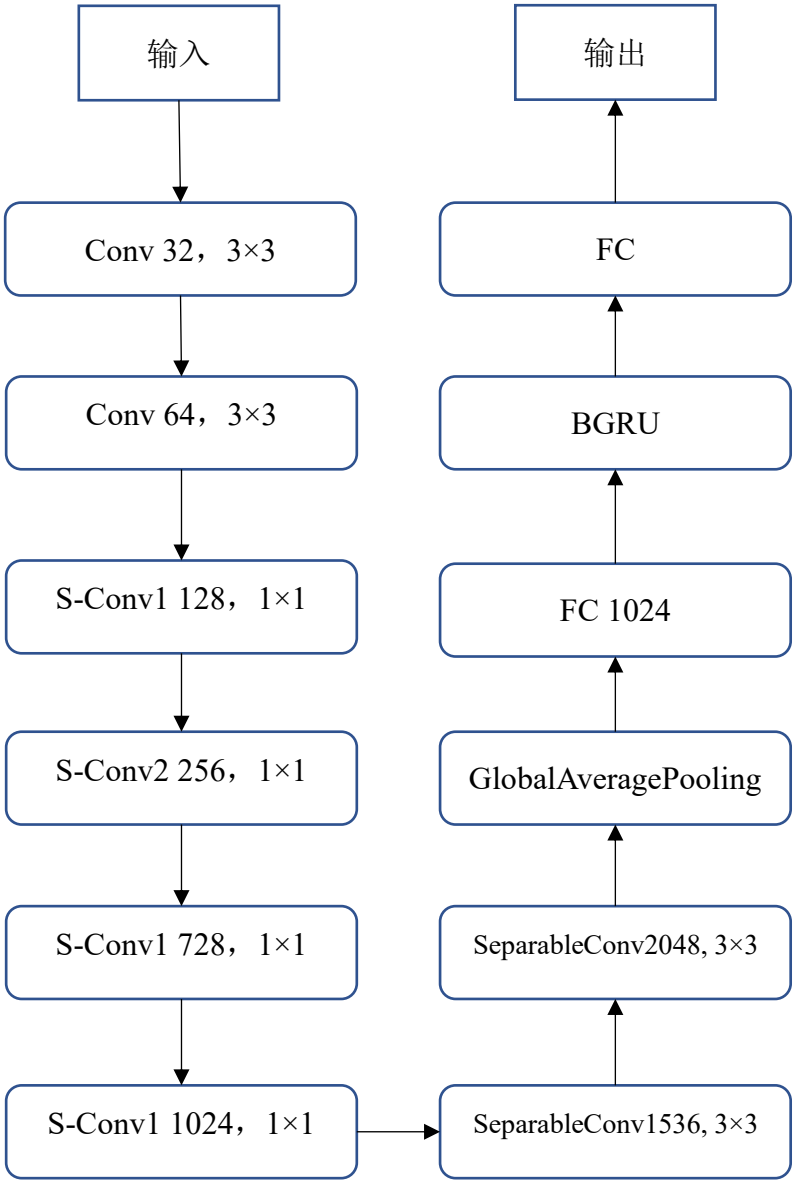

图 3-5 FCGRNN 网络结构图

Figure 3-5 FCGRNN Network Structure Diagram

3.4 混合推荐模型

降噪自动编码器可以从样本数据中学习到数据的特征或者标签、图像等,在结合传统的协同过滤推荐方法进行推荐。基于降噪自动编码器的协同过滤推荐算法的基本原理是根据构建用户与项目的评分矩阵来进行训练降噪自动编码器

中国知网 https://www.cnki.net

模型从而进行推荐。相较于基于内容的推荐，基于降噪自动编码器的协同过滤推荐算法节约了特征提取的环节,缺点是冷启动问题（新项目或者新用户没有相应的交互行为）和数据稀疏（一般情况下用户评分过的项目数远少于总项目数）。综合分析两种推荐算法的优缺点，将基于标签的推荐和基于降噪自动编码器的协同过滤算法结合以弥补冷启动和数据稀疏问题.,通过仿真实验来验证是否比传统推荐算法具有更好的效率以及准确度。

3.5 实验结果分析

根据前文所述的算法结构进行实验，将使用 NeteaseCloudMusicApi 所返回的数据存入 Dataset 数据集中，保存为本地文件 Dataset.dat。实验硬件环境为 12th Gen Intel(R) Core(TM) i5-12500H 3.10 GHz 处理器以及 NVIDIA GeForce GTX 3060，软件环境为深度学习框架 Pytorch1.11.0，Python3.6 版本。

3.5.1 音频特征提取结果分析

爬取的音频文件一般为 MP3 格式文件，通过 Python 将其转换成采样率 44100Hz 的 wav 格式文件。而音乐时长普遍在是 3 到 5 分钟左右，直接生成的梅尔频谱图的维度在 17000x1025 以上，对于输入维度较大的梅尔频谱图，可以采取一些降维处理方法，以提高训练效率。可以通过滑动窗口或者设置合适的步长对梅尔频谱图进行采样，从而减小输入维度。可以根据任务的特点和输入数据的时序性来选择合适的窗口大小和步长。

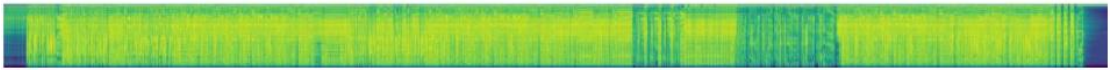

图 3-6 原始梅尔频谱图

Figure 3-6 Original Mel Spectrum

如图 3-6 就是由一首 3 分钟的音乐的频谱图转换成的原始梅尔频谱图，对其进行降维处理能够得到 16 张 1024x1024 的梅尔频谱子图。图 3-7 所示则是对经过降维处理后的子序列图。降维处理在减小输入维度的同时，尽量保留重要的信息，从而提高训练效率。

中国知网 https://www.cnki.net

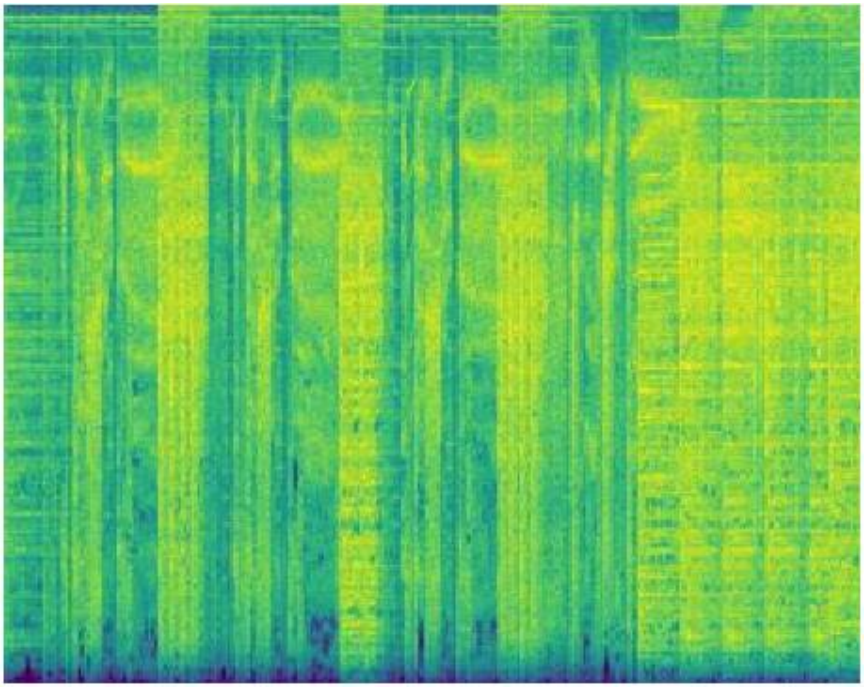

图 3-7 降维后的梅尔频谱子图

Figure 3-7 Mel frequency spectrogram after dimensionality reduction

Dataset 中音乐的总数为 25469，按照 8:2 的比例划分为训练集和测试集，训练集和测试集数据是经过 Python 降维处理，每一张标准梅尔频谱序列图都有 1024 行、1024 列和 3 个通道，一个 3 分钟时长的音频，它的梅尔频谱时间轴维度为 17368，经过降维处理可以得到 16 张标准梅尔频谱序列子图。以此 16 张梅尔频谱图输入 FCGRNN 网络作为训练，利用训练好的模型对测试集中的音乐音频转换成的梅尔频谱子图进行特征提取，从而对音乐进行分类任务。参数设置为迭代次数 300 次、Adam 自适应学习率调整算法、学习率初始值为 0.0003。

为了验证本文所提出的 FCGRNN 模型效果，选取 HCRNN、FCN6、DielemanCNN 等音乐分类方法做比较，衡量指标为准确率 ACC、AUC。不同模型的各项指标对比如表 3-4 所示。

表 3-4 结果对比表

Table 3-5 Comparison of Results

	FCN6	HCRNN	FCGRNN	DielemanCNN
Accuracy	0.581	0.834	0.8894	0.411
AUC	0.8222	0.8853	0.8999	0.7103

由实验数据可知 FCGRNN 相比如 FCN6 以及 DielemanCNN 由于加入了循环神经网络，FCGRNN 的准确率 Accuracy、AUC 均高于其他两种模型。与同样使用了 RNN 网络的 HCRNN 模型相比，CURNN 仍然领先。

中国知网 https://www.cnki.net

3.5.2 推荐模型结果分析

本文的推荐模型为基于标签推荐和基于降噪自动编码器推荐的混合推荐模型，在生成推荐列表的时候两种推荐模型各占一定比重。

选择基于受限玻尔兹曼机的推荐和传统协同过滤推荐算法与本文所提出的混合推荐模型进行对比。

验证结果的指标有两种:均方根误差（Root Mean Square Error,RMSE）和召回率（Recall）.均方根误差RMSE表示网络训练后的输出和原评分矩阵的误差,结果越小越好,如公式(3-2)所示:

$$RMSE = \sqrt{\frac{\sum_{R_{ij},\hat{R}_{ij}\in R}(R_{ij}-\hat{R}_{ij})}{n}} \tag{3-2}$$

其中,R表示测试集,n表示测试集中具有真实数据的数量,R_{ij}、$\hat{R}_{ij}$分别表示在原矩阵和网络训练输出后的矩阵中的评分.

召回率 Recall 表示生成的 Top-N 推荐列表中的项目确实是该用户评分过的项目的概率,结果越大越好，如公式(3-3)所示:

$$recall = \frac{|T\cap S|}{|S|} \tag{3-3}$$

其中,T表示经过生成的 Top-N 推荐列表,S表示测试集,$|\bullet|$表示集合中非 0 元素的个数.

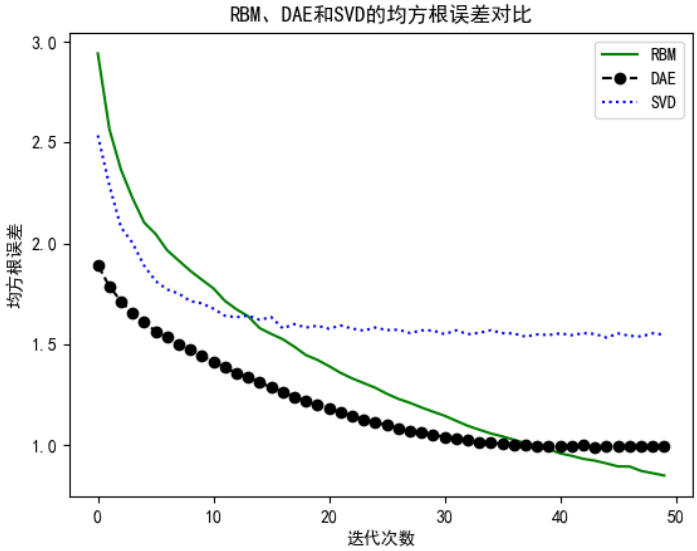

图 3-8 均方根误差对比

Figure 3-8 Root Mean Square Error Comparison

中国知网 https://www.cnki.net

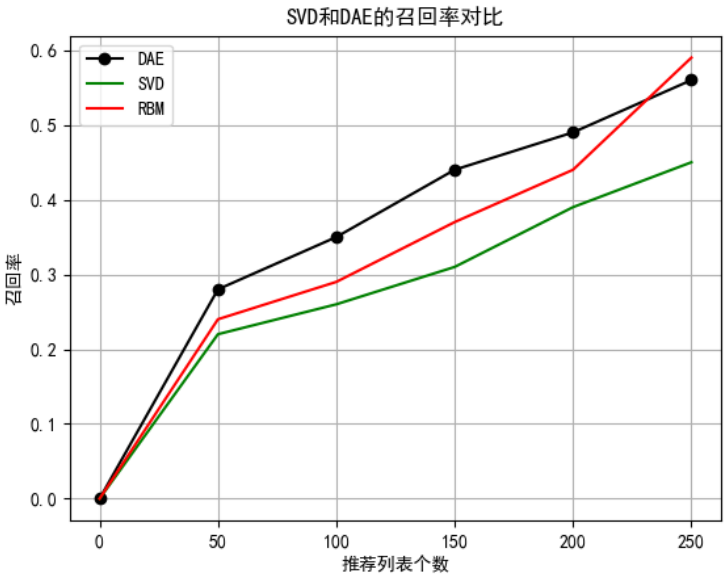

图 3-9 召回率对比

Figure 3-9 Comparison of Recall Rates

图 3-8 为三种不同推荐模型的 RMSE 与迭代次数的曲线图.可以明显看到,网络在迭代 40 次左右时开始收敛.由于初始数据加入了噪声,SVD 在收敛后性能表现非常不稳定,而 DAE 可以很好的降噪并且拥有较强的鲁棒性,RBM 在准确性方面与 DAE 不相上下,但是 RBM 中不同用户有不同的 RBM,因此训练时间更长,DAE 在拥有 150 个隐藏层神经元的情况下完成 50 次迭代仅需要 440 秒,而 RBM 则需要 3954 秒.

召回率可以通过最终生成不同长度的 Top-N 推荐列表进行对比，结果如图 3-9 所示.

显然降噪自动编码器通过学习用户兴趣爱好、项目特征等步骤,在降噪和推荐方面比传统的矩阵分解等技术具有更优的结果以及更高效的性能.

音乐混合推荐模型中，随着基于标签推荐和基于降噪自动编码器推荐比重 alpha 的取值不同，模型的准确率也不同，本文对自建的数据集进行处理，经过处理后发现用户听歌数量的中位数为 40 首，进行取用户听歌数量分别为 30、40、50 时取不同的 alpha 值情况下的实验。结果曲线图如图 3-10 所示，发现当听歌数量为 30 时 alpha 取值为 0.3 时、听歌数量为 40 时 alpha 取值为 0.5 时、听歌数量为 50 时 alpha 取值为 0.6 时推荐模型的准确率都是每条曲线的最大值；当推荐模型的准确率最高；当推荐模型的准确率最高。这说明了需要动态调整混和推荐算法中的不同推荐算法的比重，才能达到最佳的推荐效果。

中国知网 https://www.cnki.net

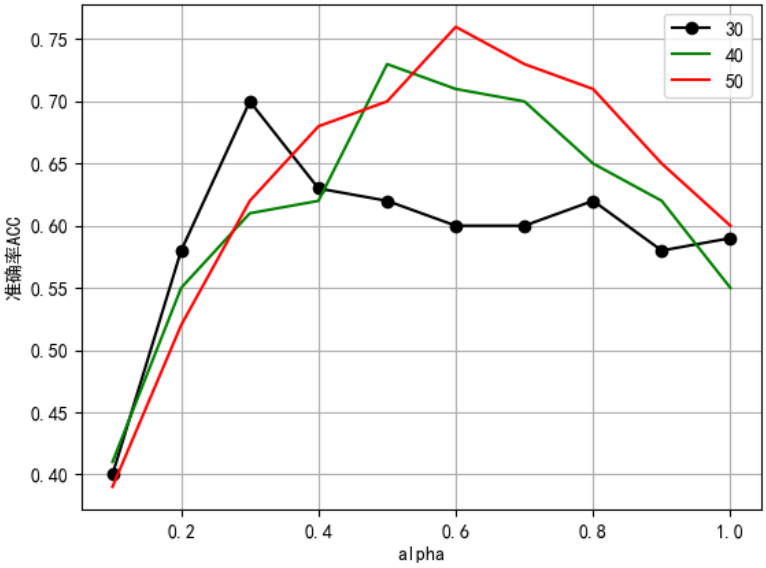

图 3-10 准确率随着比重 alpha 变化曲线图

Figure 3-10 Accuracy Curve as a Function of Specific Gravity Alpha

3.6 本章小结

本章介绍了音乐数据集的构建方法，在无法直接获取网易云音乐用户评分数据的情况下，提出了挖掘隐式规则间接构建用户评分矩阵的方法。提出了联合全卷积 FCN 和 RNN 的深度学习模型 FCGRNN。在推荐模式上采用了基于降噪自动编码器的协同过滤推荐算法，实验结果表明此模型比单独的模型、SVD 模型和基于受限玻尔兹曼机等推荐模型应用具有更佳的推荐效果。此外，通过实验证明了混合推荐模型中的两种推荐算法比重在不同的用户听歌数量时推荐的精准度也会不同，对比重进行动态调整能有效提高精准度。

中国知网 https://www.cnki.net

第 4 章 音乐推荐系统设计

数据集是通过 JavaScript 的框架 Vue 对 NeteaseCloudMusicApi 发起访问，对其返回的 JSON 格式数据进行分析、处理、保存而获得。音乐推荐系统使用 Java、Python、JavaScript 作为主要开发语言，使用 Java 的框架 Springboot 和 JavaScript 的框架 Vue 等搭建 Web 端音乐系统、Python 的 Pytorch 深度学习框架实现神经网络 FCGRNN 和降噪自动编码器的搭建，完成音乐分类、推荐任务。分类结果与数据集均通过 MySQL 数据库保存，使用 Navicat Premium 数据库管理工具。以上所提及的框架、技术均为开源产品。

4.1 需求分析

本音乐推荐系统设计的目标是要为用户提供一个推荐精准、软件好用的音乐推荐系统，该系统功能包括注册登陆、个性推荐模块、私人 FM 模块、关注模块、我的音乐模块、我的歌单模块等。其次，需要管理员模块来管理用户、音乐以及查看和修改用户偏好。系统的功能主要分为用户功能、管理员功能和系统基础功能模块。

4.1.1 用户功能分析

用户在使用音乐系统时需要注册登录、发现音乐、私人 FM、关注、我的音乐、我的歌单等功能模块，每个模块下再细分为各个小模块，如图 4-1 所示。

1.注册登录模块。用户可以注册账号，并使用账号登录系统，保护用户信息的安全。新用户注册时会提供给用户音乐偏好标签的选择，让用户根据自己的兴趣爱好进行选择，以便更好的进行推荐；

2.个性推荐模块。展示由后台推荐算法为用户生成推荐列表，包括为用户推荐的每日歌曲列表、歌单列表、歌手列表等；

3.私人 FM 模块。为用户即时生成单个推荐歌曲，由用户给出反馈（收藏、喜欢、不喜欢等）从而改变用户对不同种风格音乐的偏好程度；

4.关注模块。展示用户关注的歌手的最新动态，主要为发布新歌、新专辑等；

5.我的音乐模块。在本模块下分为喜欢的音乐、最近播放等子模块，可以让更好的帮助推荐系统分析用户的喜好；

6.我的歌单模块。在本模块下分为创建的歌单和收藏的歌单两个模块，主

中国知网 https://www.cnki.net

要展示用户自己创建的歌单以及收藏推荐列表中的歌单列表。

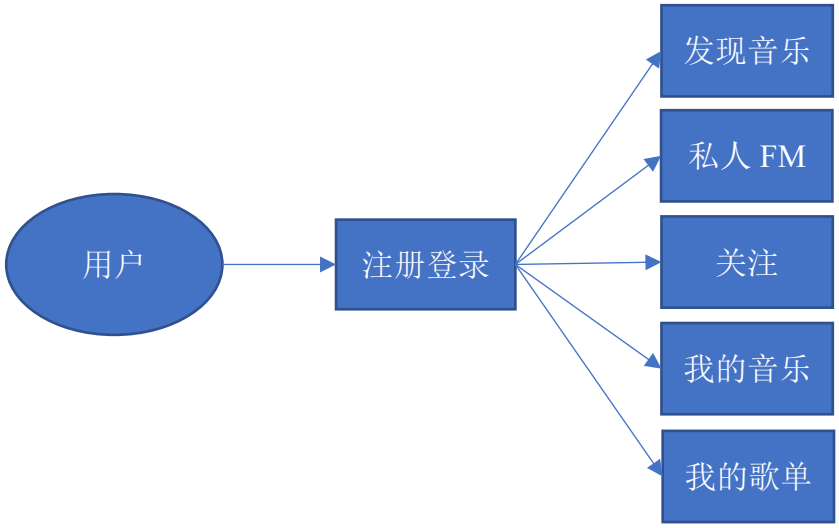

图 4-1 用户功能图

Figure 4-1 User Function Diagram

4.1.2 管理员功能分析

管理员功能主要负责管理用户、音乐等数据，需要对用户信息、收藏信息、播放信息、推荐信息、评论信息、音乐信息等进行管理，如图 4-2 所示。

1.用户信息管理：管理员可以管理用户账号，包括用户注册信息的审核、账号的封禁和解禁等。

2.收藏信息管理：管理员可以查看后台实时记录下的用户收藏操作，包括收藏时间、收藏音乐、收藏用户等信息。

3.播放信息管理：管理员可以通过检索用户 ID 查看用户的播放记录。

4.推荐信息管理：管理员可以查看管理系统的推荐列表信息、用户实时反馈信息等。

5.评论信息管理：管理员可以查看、删除、修改用户对音乐的评论信息。

6.音乐信息管理：管理员可以管理歌曲的信息，包括歌曲的上传、编辑、删除等。

中国知网 https://www.cnki.net

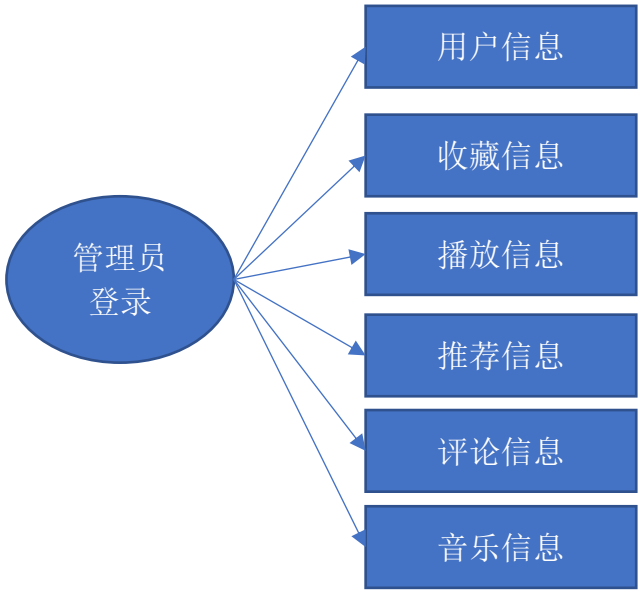

图 4-2 管理员功能模块

Figure 4-2 Administrator Function Module

4.1.3 系统基础功能分析

一个好用的系统，除了完善的功能外还需要考虑的几个非功能性指标：

1.可靠性：系统的可靠性是一个关键指标，确保系统在面对突发问题时依然能够提供稳定的服务。这包括对系统进行健壮性设计，考虑错误处理和异常情况，并提供相应的应急方案和错误恢复策略。系统的可靠性还包括对数据的保护和备份，以防止数据丢失或损坏。

2.可扩展性：系统的可扩展性是指系统能够在需求变化时容易扩展，包括业务功能的扩展和性能的扩展。系统应该具有良好的模块化设计和接口设计，以便于新增功能的集成和拓展。同时，系统应该支持水平扩展和垂直扩展，以满足不断增长的用户需求。

3.可维护性：系统的可维护性是指系统易于进行维护和修复，包括代码的规范性、注释和文档的完善性。系统应该采用清晰的代码结构和命名规范，遵循软件工程的最佳实践，以便于后续的维护和修改。同时，系统应该具有良好的日志记录和错误监控，便于排查和解决问题。

4.可恢复性：系统的可恢复性是指系统能够在出现故障或错误时快速恢复正常运行。系统应该具有错误检测和错误处理机制，包括故障检测、故障恢复

中国知网 https://www.cnki.net

和数据恢复。系统还应该具有灾备和备份策略，以确保数据和系统在发生灾难性事件时能够恢复到正常状态。

5.用户体验：除了系统的功能需求，用户体验也是非常重要的指标。系统的界面设计应该简洁、易用，符合用户的习惯和期望。系统的响应速度和性能也应该足够高，以保证用户的流畅使用体验。此外，系统应该具有良好的错误处理和用户反馈机制，以便及时解决用户的问题和反馈。

综上所述，要实现一个好用的系统，除了功能需求外，还需要充分考虑系统的可靠性、可扩展性、可维护性、可恢复性和用户体验等非功能性指标，以保障系统的稳定运行和用户的良好体验。

4.2 数据库设计

数据库设计是构建一个高效、可靠和可扩展的数据库系统的关键步骤。

4.2.1 数据库设计原则

数据库设计是构建一个高效、可靠和可扩展的数据库系统的关键步骤。以下是一些常用的数据库设计原则：

1.规范化（Normalization）：规范化是数据库设计的基本原则，旨在通过消除冗余数据和确保数据一致性来提高数据库的效率和可靠性。规范化通常包括将数据库表拆分成更小、更规范化的表，以减少数据冗余和避免更新异常。

2.数据完整性（Data Integrity）：数据完整性是指数据库中的数据必须始终保持一致和准确。数据库设计应该包括适当的数据类型、长度、格式和约束，以确保只有有效的数据被存储和处理，并防止数据不一致或错误。

3.主键和外键（Primary Key & Foreign Key）：主键用于唯一标识数据库表中的每一行数据，外键用于建立表之间的关联关系。正确使用主键和外键可以帮助维护数据库的数据一致性和完整性，并支持数据的关联查询和连接操作。

4.性能优化（Performance Optimization）：数据库设计应该考虑到系统的性能需求，包括对大数据量、高并发和复杂查询的支持。使用适当的索引、优化查询语句、合理的数据类型选择和数据分区等技术可以提高数据库系统的性能。

5.安全性（Security）：数据库设计应该考虑到系统的安全需求，包括对敏感数据的保护、用户权限的管理和访问控制等。采用合适的加密技术、防范 SQL 注入攻击、设置严格的用户权限和审计等措施可以保障数据库系统的安全性。

6.可扩展性（Scalability）：数据库设计应该具有良好的可扩展性，以满足日

中国知网 https://www.cnki.net

益增长的数据和用户需求。设计合适的数据库结构、使用分布式数据库或缓存技术、采用水平扩展和垂直扩展等策略可以支持系统的可扩展性。

7.简洁性（Simplicity）：数据库设计应该保持简洁，避免不必要的复杂性。简洁的数据库设计可以减少系统的复杂性和维护成本，并提高系统的可读性和可理解性。

8.文档化（Documentation）：数据库设计应该进行充分的文档记录，包括设计决策、表结构、索引、约束、存储过程等详细信息。充分的文档可以帮助数据库管理员和开发人员理解数据库设计，并在维护和更新数据库时提供指导。

4.2.2 表属性介绍

通过系统需求可以分析得到需要建立的表以及表中的字段，主要包括用户基本信息表、音乐基本信息表、收藏信息表、播放信息表、评论信息表以及推荐信息表，具体属性如下所述。

1. 用户基本信息表：

(1)用户 ID：唯一标识用户的 ID

(2)用户名：用户的用户名

(3)密码：用户的密码。

(4)邮箱：用户的邮箱地址，可用作通知或者修改密码用。

(5)用户偏好：注册时用户自行勾选偏好。

2.音乐基本信息在音乐推荐系统中包括：

(1)音乐 ID：唯一标识音乐的 ID。

(2)音乐名称：音乐的名称。

(3)下载地址：音乐的 URL 下载地址。

(4)音乐标签：音乐所属标签类型。

(5)音乐添加时间：音乐添加进系统的时间。

3.收藏信息在该系统中包括：

(1)收藏 ID：唯一标识收藏记录的 ID。

(2)用户 ID：收藏音乐的用户 ID。

(3)歌曲 ID：被收藏的音乐 ID。

(4)收藏时间：收藏音乐的日期。

4.播放信息在该系统中包括：

(1)播放 ID：唯一标识播放记录的 ID

(2)用户 ID：播放音乐的用户 ID

(3)音乐 ID：被播放的音乐 ID

(4)播放时间：播放的时间

中国知网 https://www.cnki.net

(5)播放次数：被播放音乐的次数
5.评论信息在该系统中包括：
(1)评论 ID：唯一标识评论记录的 ID
(2)用户 ID：评论歌曲的用户 ID
(3)音乐 ID：被评论的音乐 ID
(4)评论内容：评论的内容
(5)评论时间：评论的时间
6.推荐信息表在该系统中包括：
(1)推荐 ID：唯一标识推荐记录的 ID
(2)用户 ID：推荐歌曲的用户 ID
(3)音乐 ID：被推荐的歌曲 ID
(4)推荐时间：推荐的时间

4.2.3 表结构设计

用户基本信息表用来存放用户基本信息，表结构如表 4-1 所示。

表 4-1 用户基本信息表

Table 4-1 Basic User Information Table

名	类型	长度	不是 null	--	虚拟	键
userID	int	30	√	--	--	1
userName	varchar	50	√	--	--	--
password	varchar	30	√	--	--	--
email	varchar	50	√	--	--	--
preference	int	50	--	--	--	--

音乐基本信息用来存储音乐的基本信息，主要用来存储音乐的唯一标识、音乐名、歌手、下载地址、音乐类型以及音乐添加时间等信息，具体如表 4-2 所示：

表 4-2 音乐基本信息表

Table 4-2 Basic Music Information Table

名	类型	长度	不是 null	虚拟	键
songID	int	30	√	--	1
songName	varchar	50	√	--	--
singerID	int	30	√	--	--
singerName	varchar	50	√	--	--
songURL	varchar	255	√	--	--

中国知网 https://www.cnki.net

名	类型	长度	不是 null	虚拟	键
songType	varchar	255	√	--	--
songDate	datetime	--	√	--	--

收藏信息表用来存放某个用户对于某首歌曲的收藏，一条收藏信息记录对应一个唯一用户 ID 以及一个唯一歌曲 ID，以及该收藏所对应的时间，具体如表 4-3 所示：

表 4-3 收藏信息表

Table 4-3 Favorite Information Table

名	类型	长度	不是 null	虚拟	键
collectID	int	30	√	--	1
userID	int	30	√	--	--
songID	int	30	√	--	--
collectDate	datetime	--	√	--	--

播放信息表用来存放某个用户对于某首歌曲的历史记录信息，如表 4-4 所示：

表 4-4 播放信息表

Table 4-4 Playback Information Table

名	类型	长度	不是 null	虚拟	键
playID	int	30	√	--	1
userID	int	30	√	--	--
songID	int	30	√	--	--
playDate	datetime	--	√	--	--
playTime	Int	255	√	--	--

评论信息表用来存放某个用户对于某首歌曲的评论信息，如表 4-5 所示：

表 4-5 评论信息表

Table 4-5 Comment Information Table

名	类型	长度	不是 null	虚拟	键
reviewID	20	30	√	--	1
userID	20	30	√	--	--
songID	20	30	√	--	--
reviewDate	datetime	--	√	--	--
reviewContent	varchar	255	√	--	--

推荐信息表用来存放对某一个用户的推荐记录，其具体内容如表 4-6 所示：

表 4-6 播放信息表

中国知网 https://www.cnki.net

Table 4-6 Playback Information Table

名	类型	长度	不是 null	虚拟	键
recommendID	int	30	√	--	1
userID	int	30	√	--	--
songID	int	30	√	--	--
recommendDate	datetime	--	√	--	--

4.3 系统整体设计

本系统采用用 B/S 设计模式，项目部署后，只需要通过浏览器访问域名即可对进入音乐推荐系统。相比于 C/S 模式，不需要开发客户端，降低了开发成本。后端采用 SpringBoot 的框架，前端使用继承了 Thymeleaf 的 Vue 框架。后端使用 Java 语言，Idea 作为开发工具。关系型数据库采用 MySQL，非关系数据库使用 Redis。

系统开发采用标准的 MVC 模式，将业务分为 Controller、Service、Mapper 三层。Controller 层主要与用户传递过来的请求交互，然后根据请求情况，调用相应的 Service 层接口来进行处理，处理完成之后会获得数据，将数据传递给 Vue 框架进行数据渲染展示给用户。Service 层主要负责调用 Mapper 接口，将返回的结果封装成 Service 类供 Controller 层调用。Mapper 层属于是数据持久层，由 Mybatis 框架负责，其内每一个 Mapper 文件对应数据库内每张表的封装实体类，每一个类里面封装了增删改查的操作对应 sql 语句。对于负责某一功能的 Mapper 类，，由 Service 向此 Mapper 类传递 sql 语句中缺少的参数，之后 Mybatis 就会执行该 sql 语句，然后 Mapper 就会把数据库操作结果返回给 Service 层，增删改返回状态码，查返回实体对象数据。

系统软硬件开发环境如表 4-7 所示。

表 4-7 系统软硬件开发环境

Table 4-7 System Software and Hardware Development Environment

类别	版本
CPU	12th Gen Intel(R) Core(TM) i5-12500H 3.10 GHz
操作系统	Ubuntu16.04
GPU	NVIDIA Geforce RTX 3060
服务器	阿里云服务器
Java	JDK 17 LTS
Springboot	2.7.10
Maven	apache-maven-3.8.1

中国知网 https://www.cnki.net

类别	版本
Idea	2021.2.2 professional
MySQL	8.0.16
Navicat Premium	15
Vue	3.0

4.4 本章小结

本章主要对系统需求进行了分析，确定了用户的功能需求和管理员的功能需求，用户的功能需求包括在系统中对于相关模块的操作，以及对于音乐的操作，管理员的功能需求主要包括后台对于一些信息的记录和管理，并且对前端和服务端所需的技术进行了选型，设计好了系统所需要的数据库表字段，确定了系统的架构以及开发部署所需要的环境。

中国知网 https://www.cnki.net

第 5 章 推荐系统的实现

本章将对各个核心功能模块进行开发实现。开发环境如表 4-7 所示。在下文中展示各个核心功能模块的具体实现。该音乐推荐系统的 web 端主界面如图 5-1 所示：

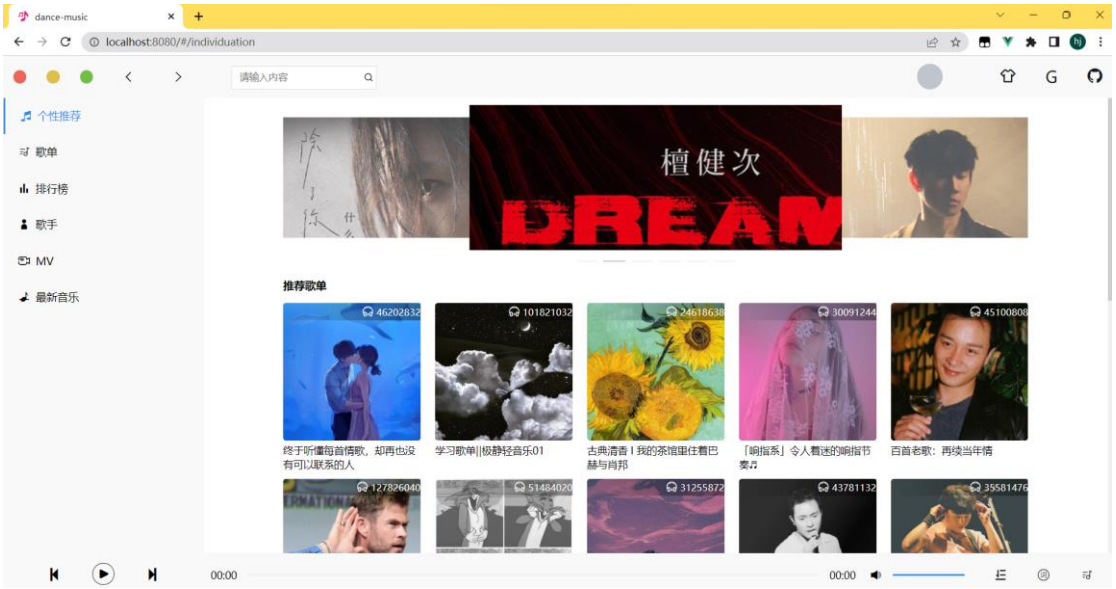

图 5-1 web 主界面

Figure 5-1 Web Main Interface

5.1 用户核心模块实现

5.1.1 登陆注册模块

如图 5-2 所示，用户在进入 web 端主界面后，需要先进行登陆或者注册，登录时，后台会将通过用户名查询密码，再进行密码校验，如果一致则验证通过，如果密码错误则提示用户重新输入密码。新用户注册需要填写用户名、密码和邮箱，注册成功后会弹出音乐标签供用户选择偏好。注册时后台查询当前的用户名是否已经存在数据库中，如果没有则注册成功，并将用户的注册信息存入数据库中。

中国知网 https://www.cnki.net

图 5-2 登录注册界面

Figure 5-2 Login and Registration Interface

5.1.2 发现音乐模块

发现音乐模块由个性推荐、歌单、排行榜、歌手等子模块组成，如图 5-3 和图 5-4 所示。

中国知网 https://www.cnki.net

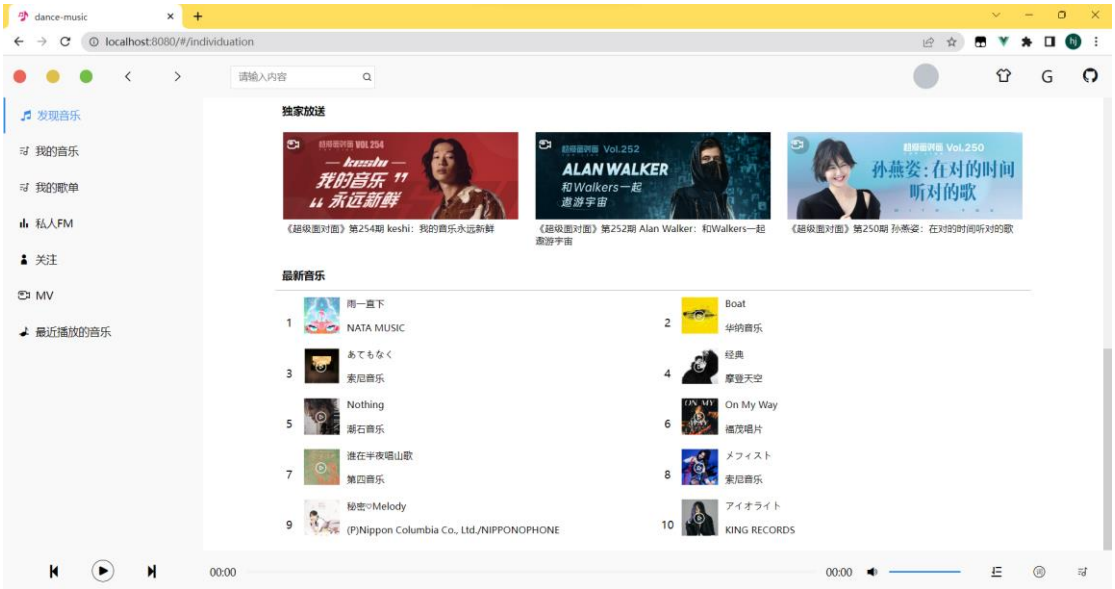

图 5-3 发现音乐模块中个性推荐模块

Figure 5-3: Discovering the Personalized Recommendation Module in the Music Module

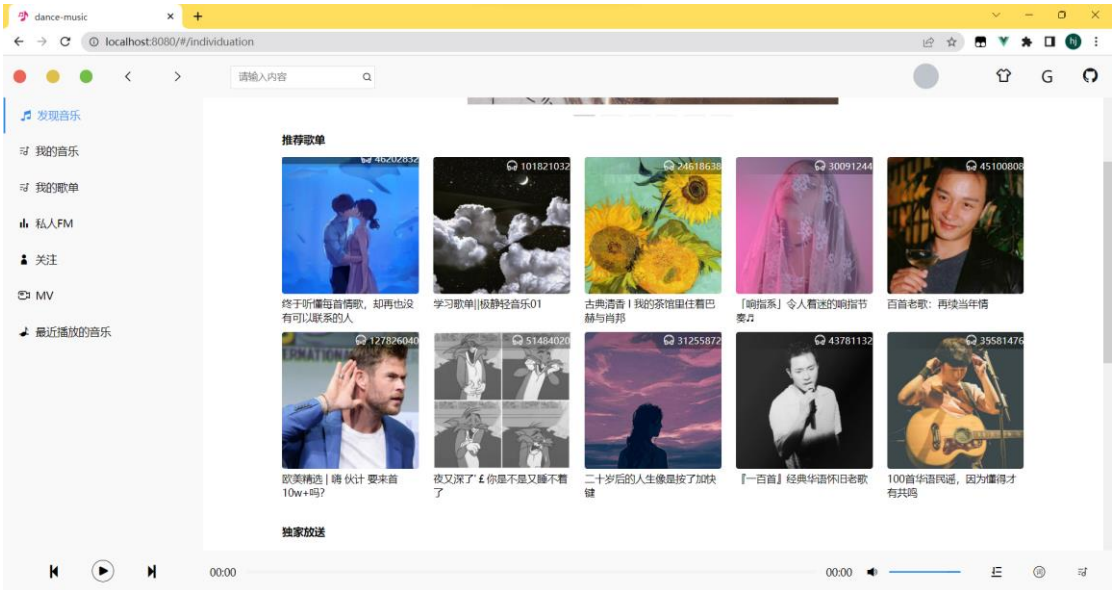

图 5-4 发现音乐模块中歌单推荐模块

Figure 5-4: Discovering the Singles Recommendation Module in the Music Module

中国知网 https://www.cnki.net

5.1.3 我的歌单模块

我的歌单模块由创建的歌单与收藏的歌单组成，如图 5-5 所示。

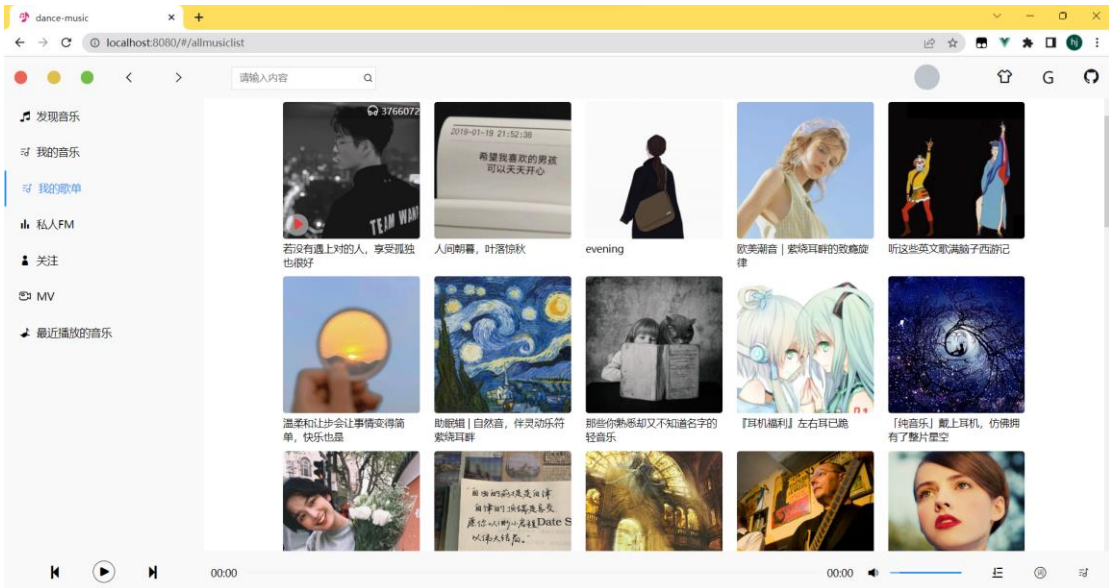

图 5-5 我的歌单模块

Figure 5-5 My Singing List Module

5.1.4 私人 FM 模块

私人 FM 模块针对用户给出推荐列表，并且根据用户的反馈及时对推荐模型进行参数更新，用户的反馈包括喜欢、删除、下一首等，如图 5-6 所示。

中国知网 https://www.cnki.net

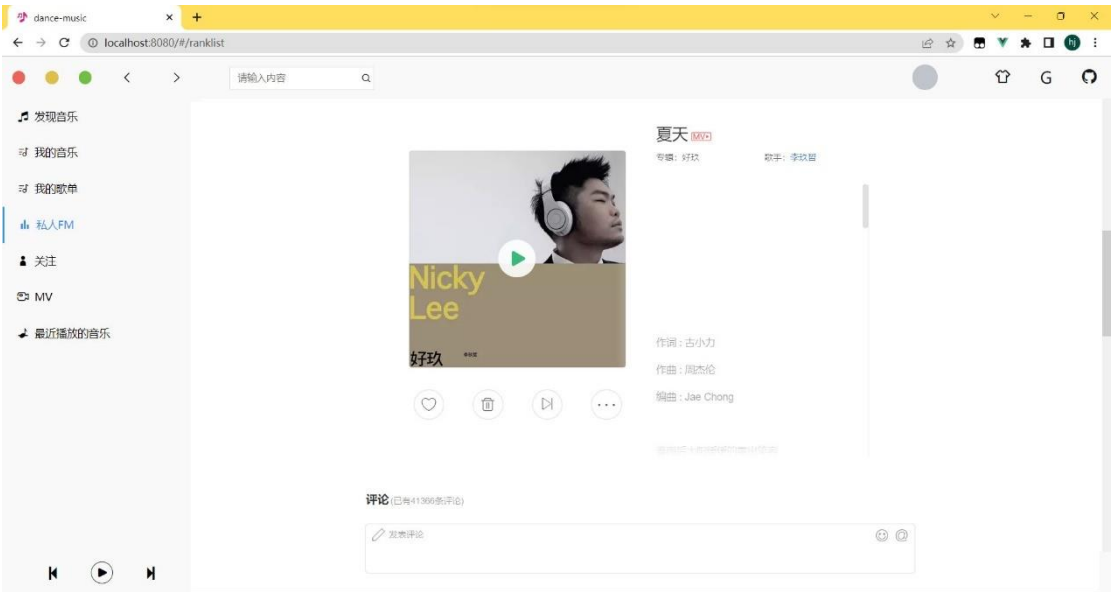

图 5-6 私人 FM 模块

Figure 5-6 Private FM Module

5.1.5 关注模块

此模块下为关注的歌手的动态，在此查看歌手的最新动态，如图 5-7 所示。

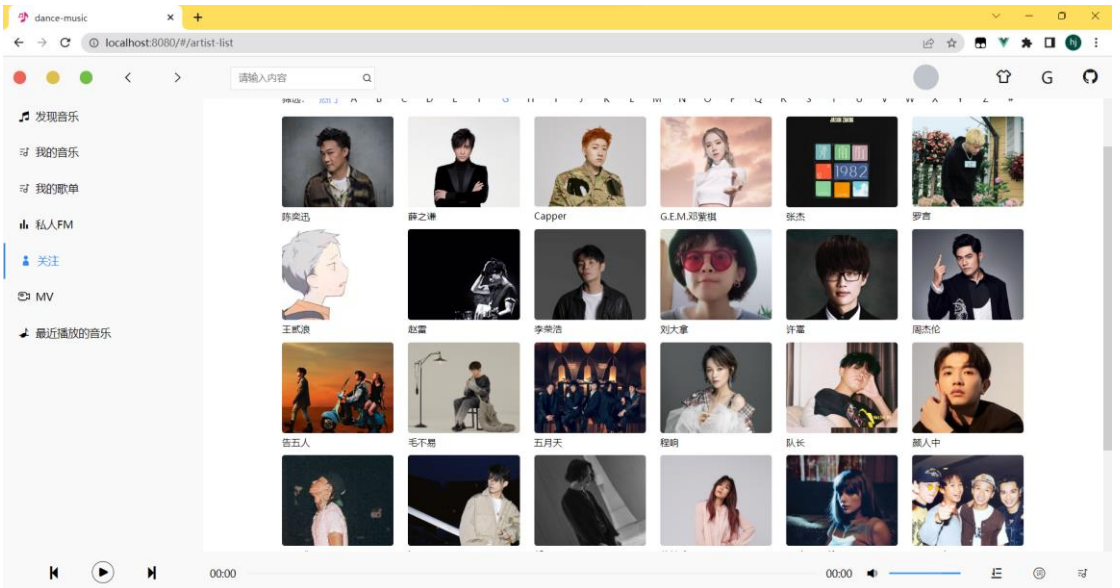

图 5-7 关注模块

Figure 5-7 Focus Module

中国知网 https://www.cnki.net

5.2 管理员核心模块实现

根据前文的模块设计分析，实现管理员应有的功能，包括用户信息管理、音乐信息管理、推荐信息管理、播放信息管理等。管理员界面需要通过登录时输入管理员用户密码再点击管理员登录才能进入，进入时默认进入用户信息管理界面。

5.2.1 用户信息管理模块

用户信息管理模块可以显示已经注册用户的所有信息，包括用户的注册时间，用户 ID，用户密码（默认情况不可见）、用户邮箱、用户偏好等内容，如图 5-8 所示。

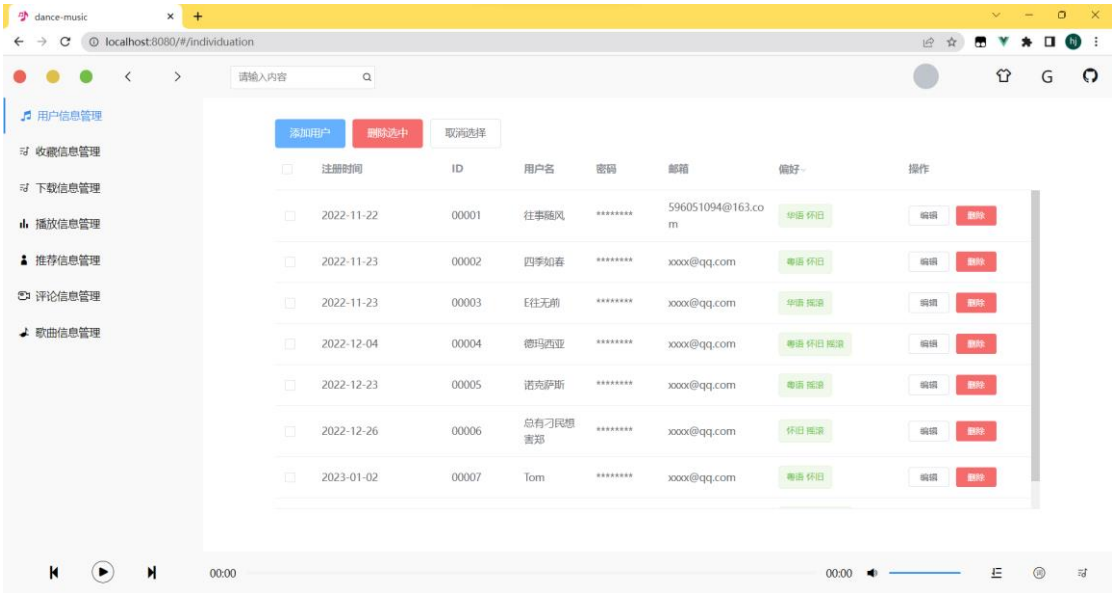

图 5-8 用户信息管理模块

Figure 5-8 User Information Management Module

管理员可以对用户信息做注册新用户、注销旧用户、修改用户信息、查找检索用户信息等功能。除批量注销旧用户操作外，每一项操作后都需要再次验证管理员密码。

中国知网 https://www.cnki.net

5.2.2 音乐信息管理

音乐信息模块可以显示数据库内包含的所有歌曲的基本信息、音乐 ID、音乐名、音乐下载地址、音乐类型、音乐添加时间等，如图 5-9 所示。

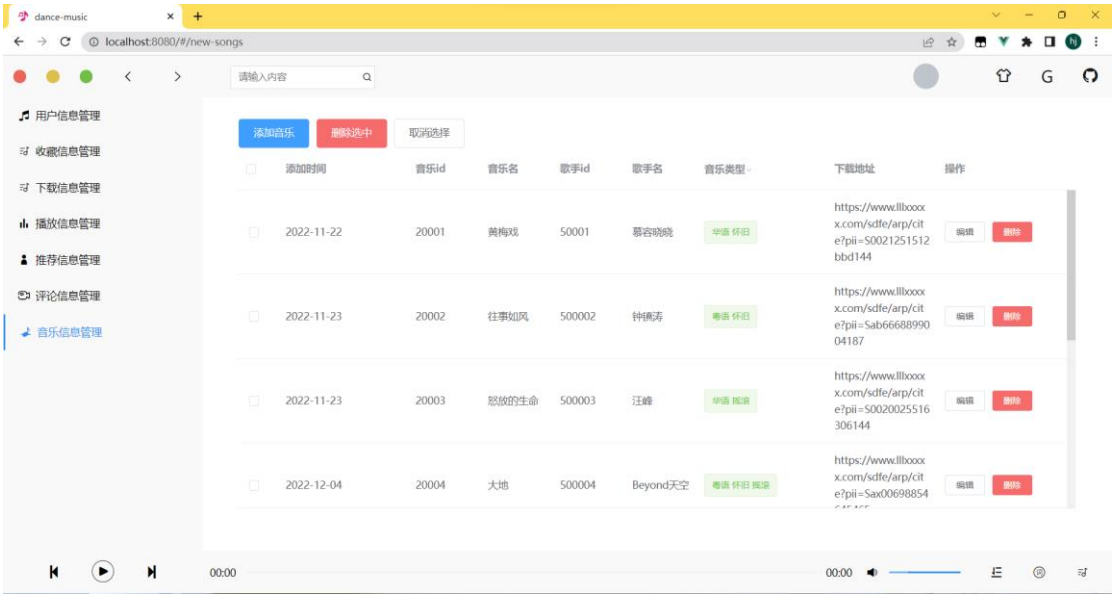

图 5-9 音乐信息管理模块

Figure 5-9 Music Information Management Module

管理员可以对音乐做添加音乐、删除音乐、修改音乐信息、查找检索音乐信息等功能。

5.2.3 推荐信息管理

推荐信息管理模块主要通过检索用户 ID 获得推荐模型对用户的推荐内容，包括推荐列表 Top-N、推荐歌单、以及用户对推荐内容的反馈等信息，如图 5-10 所示。

中国知网 https://www.cnki.net

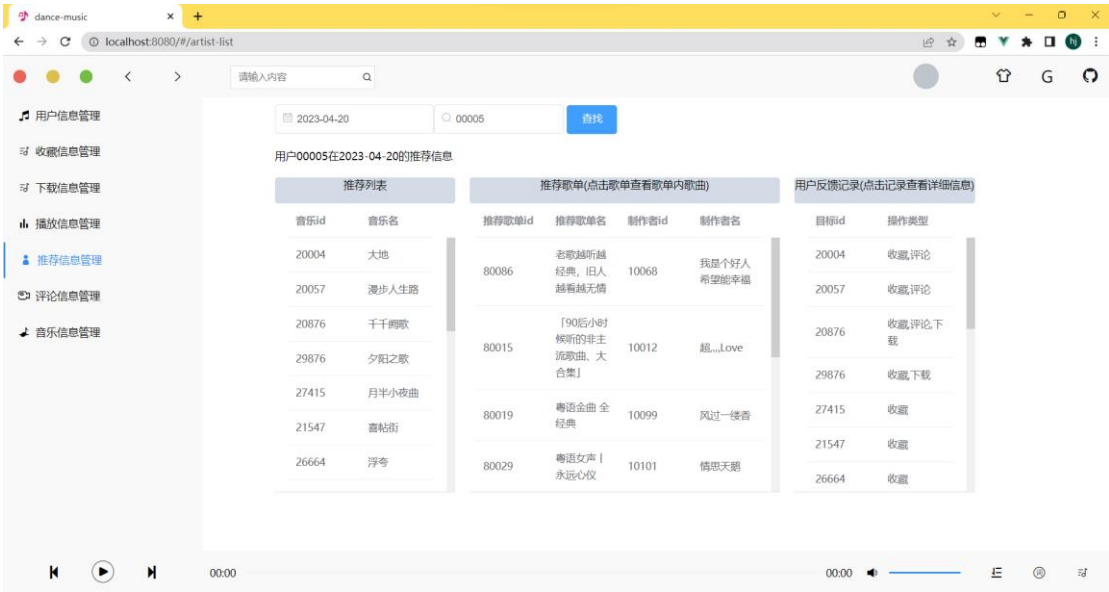

图 5-10 推荐信息管理模块

Figure 5-10 Recommendation Information Management Module

5.2.4 播放信息管理

播放信息管理模块通过检索用户 ID 获得用户最近播放过的音乐，用户的播放历史记录是推荐模型生成推荐内容的重要参考信息。管理员可以根据用户的反馈修改这部分内容，从而间接的影响推荐模型对用户的推荐方法，如图 5-11 所示。

中国知网 https://www.cnki.net

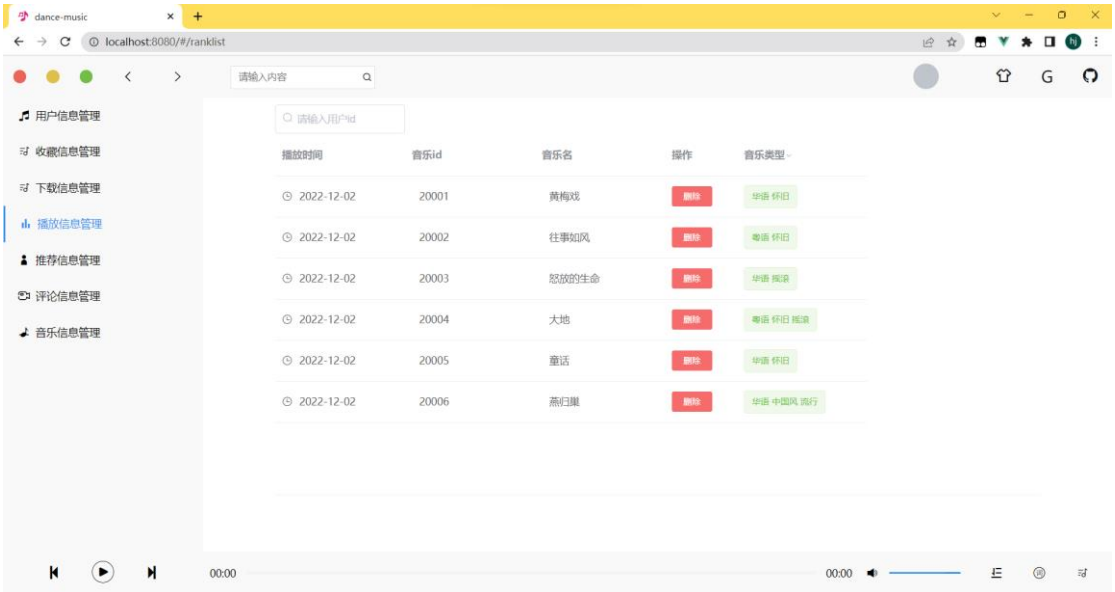

图 5-11 播放信息管理模块

Figure 5-11 Playback Information Management Module

5.3 本章小结

本章展示了根据需求分析做出来的系统功能，展示用户的注册模块、推荐列表、我的歌单、私人 FM 模块等核心模块以及管理员的用户信息管理模块、音乐信息管理模块、推荐信息模块等。

中国知网 https://www.cnki.net

总结和展望

本文首先分析了音乐推荐系统的研究目的和意义，概括了推荐算法和深度学习在推荐系统方向的应用与现状。详细介绍了本文提出的联合深度神经网络 FCGRNN 模型以及联合基于降噪自动编码器的协同过滤推荐算法与基于标签的推荐算法的分析与设计。

FCGRNN 模型利用全卷积网络提取梅尔频谱图音乐特征，再通过循环神经网络，继续获取音乐频谱在隐含的特征联系。相比于卷积神经网络 FCGRNN 模型具有增加网络深、保留空间信息、减少网络参数等特点，同时又比 RNN 模型具有更少的参数量。创新点在于引入双向 GRU 学习长期音频模式进而利用未来信息。通过实验对比分析, FCGRNN 的分类效果远高于 DielemanCNN、FCN6、HCRNN 模型。

而混合基于降噪自动编码器的协同过滤推荐和基于标签的推荐算法预测结果的 RMSE 值比单独的协同过滤模型、基于受限玻尔兹曼机模型、K-Means 模型低，实验结果表明降噪自动编码器的协同过滤推荐算法比单独的模型应用具有更佳的推荐效果，还实验发现了用户听歌数量的多少也会影响混合推荐模型中两种算法的占比，进而影响准确率。现将本文的主要工作总结如下：

1.自建数据集没有直接的用户评分矩阵，因此无法直接获取用户对音乐的评分值。本文通过挖掘其中的隐式规则间接构建用户评分矩阵。提出了利用用户播放记录次数的数据来建立用户评分矩阵。

2.提出了联合全卷积网络和循环神经网络模型。后置的循环神经网络结构中则引入了双向 GRU，学习长期音频模式进而利用未来信息。

3.提出了混合基于降噪自动编码器的协同过滤推荐算法和基于标签的推荐模型，有效解决传统协同过滤的稀疏性问题。当用户听歌数量较大的时候增加基于降噪自动编码器的协同过滤模型的占比，反之则增加基于标签的推荐模型的占比。

4.基于 Springboot+vue 的前后端分离项目实现了小型音乐推荐系统，实现了音乐系统的基本功能。

本文在算法设计和系统实现上还有许多不足之处，总结如下：

受限于深度深度神经网络的参数量和训练速度，本文实现的音乐推荐系统是算法部分与开发部分没有实时沟通，需要将需要数据临时保存再读取，大大降低了系统的响应速度以及模型的训练时间。后续可以进一步优化网络结构，提高计算效率，做到系统实时相应、模型实时推荐。在高并发场景下对各个接口进行测试，部分接口无法通过测试软件，后续将进一步优化接口调度。

中国知网 https://www.cnki.net

参考文献

[1] 国家互联网信息办公室.2021 年中国互联网络发展状况统计报告[R].北京:中国互联网络信息中心.2021:1-7.

[2] [1]宋雪峰. 基于深度学习的个性化音乐推荐系统设计与实现[D].黑龙江大学,2021.DOI:10.27123/d.cnki.ghlju.2021.001626.

[3] Baccigalupo C , Plaza E . Case-Based Sequential Ordering of Songs for Playlist Recommendation[J]. European Conference on Case-Based Reasoning. ECCBR.2006.11(07):43-58.

[4] 万姝懿,闫大卫.我国网络音乐市场发展现状研究[J].艺术教育.2014.21(04):72-73.

[5] 丁明波. 基于深度学习的个性化音乐推荐方法研究[D].中国石油大学(华东).2017:34-42.

[6] 何蓉. 基于卷积神经网络的音乐推荐系统[D].南京邮电大学.2019:32-45.

[7] Goldbergd N D, Oki B M. Using Collaborative Filtering to Weave an Information Apestry[J]. Communications of the ACM. 1992. 35(12): 61-70.

[8] Starr B, Ackerman M S, Pazzani M. Do-I-Care: A collaborative web agent[C].International Conference on Intelligent User Interfaces.IUI.1996: 273-274.

[9] P. Resnick, N. Iacovou, M. Suchak, et al. An open architecture for collaborative filtering of Netnews[C]. ACM Conference on Computer Supported Cooperative Work, Chapel Hill, 1994, 175-186.

[10] Bollacker, Kurt D , Lawrence, et al. Discovering Relevant Scientific Literature on the Web.[J]. IEEE Intelligent Systems & Their Applications.IEEE.2000.41(03):29–39.

[11] Sánchez-Moreno D, Pérez-Marcos J, González A B G, et al. Social influence-based similarity measures for user-user collaborative filtering applied to music recommendation[C].International Symposium on Distributed Computing and Artificial Intelligence. Springer, Cham.2018: 267-274.

[12] Kai H. Automatic Recommendation Algorithm for Video Background Music Based on Deep Learning[J]. Complexity.2021.04(04):32-45.

[13] Mao Y, Zhong G, Wang H, et al. MCRN: A New Content-Based Music Classification and Recommendation Network[C].International Conference on Neural Information Processing. Springer, Cham.2020: 771-779.

[14] Yang H, Zhao Y, Xia J, et al. Music playlist recommendation with long short-

中国知网 https://www.cnki.net

term memory[C].International Conference on Database Systems for Advanced Applications. Springer, Cham.2019: 416-432.

[15] Jia N , Zheng C J . Model of Music Theme Recommendation Based on Attention LSTM[J]. Computer Science.2019.42(07):21-30.

[16] M. D. Zeiler and R.Fergus.Visualizing and understanding convolutional networks[C].European Conference on Computer Vision.ECCV.2014:423–442.

[17] K. Simonyan and A. Zisserman.Very deep convolutional networks for large-scale image recognition[C].International Conference on LearningRepresentations.ICLR.2015:6-10.

[18] Zhou G , Mou N , Fan Y , et al. Deep Interest Evolution Network for Click-Through Rate Prediction[J]. Proceedings of the AAAI Conference on Artificial Intelligence.AAAI.2019.33(04):5941-5948.

[19] 冯楚滢, 司徒国强, 倪玮隆. 协同深度学习推荐算法研究[J]. 计算机系统应用, 2019, 28(01):171-177.

[20] Feng Y , Lv F , Shen W , et al. Deep Session Interest Network for Click-Through Rate Prediction[C].International Joint Conference on Artificial Intelligence .IJCAI.2019:58-66.

[21] 王永和, 张劲松, 邓安明,等. Spring Boot 研究和应用[J]. 信息通信, 2016, 000(010):91-94.

[22] 张雷, 王悦. 基于 SpringBoot 微服务架构下的 MVC 模型研究[J]. 安徽电子信息职业技术学院学报, 2018, 97(04):5-13.

[23] 曾凡聪. 个性化音乐推荐系统[D]. 电子科技大学,2021.DOI:10.27005/d.cnki.gdzku.2021.004832.

[24] Kiam Tan Y, Xu X, Liu Y. Improved Recurrent Neural Networks for Session-based Recommendations[J].The ACM Confererce Serise on Recommender Systens.RecSys.2016.32(09):30-51.

[25] 朱志慧,田婧,林捷.大数据环境下基于用户位置的个性化音乐推荐系统设计[J].无线互联科技.2019.16(02):85-86.

[26] Wang J, Huang P, Zhao H, et al. Billion-scale commodity embedding for e-commerce recommendation in alibaba[C].Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. KDD.2018: 839-848.

[27] Li L, Chu W, Langford J, et al. A contextual-bandit approach to personalized news article recommendation[C].Proceedings of the 19th international conference on World wide web.WWW.2010:661-670.

[28] 江水.基于协同过滤技术推荐系统的探究[J].计算机技术与发

中国知网 https://www.cnki.net

展,2021,31(11):1-7
[29] 储雯倩, 丛挺. 音乐社交 APP 互动仪式链研究——以网易云音乐为例[J]. 未来传播.2020.28(3):67-73.
[30] Elbir A M . DeepMUSIC: Multiple Signal Classification via Deep Learning[J]. IEEE Sensors Letters.2020.4(4):1-4.
[31] Huang Y , Huang X , Cai Q . Music Generation Based on Convolution-LSTM[J]. Computer & Information Science.2018.11(3):50-56.
[32] Ly T H , Do S T , Nguyen T T S . Ontology-based Recommender System for the Million Song Dataset Challenge[C].2018 10th International Conference on Knowledge and Systems Engineering (KSE). 2018:25-35.
[33] Lacayo R , Pesaresi L , Gross J , et al. Nonlinear modeling of structures with bolted joints: A comparison of two approaches based on a time-domain and frequency-domain solver[J]. Mechanical Systems & Signal Processing.2019.114(JAN.1):413-438.
[34] Lu Z , Ma F , Yang C , et al. A novel method for Estimating Time of Flight of ultrasonic echoes through short-time Fourier transforms[J]. Ultrasonics.2020.21(05):103-106.
[35] Wei Y , Li C , Li T , et al. Whispered Speech Enhancement Based on Improved Mel Frequency Scale and Modified Compensated Phase Spectrum[J]. Circuits, systems, and signal processing.2019.38(12):5839-5860.
[36] Ilyas M , Othmani A , Nait-Ali A . Auditory perception based system for age classification and estimation using dynamic frequency sound[J]. Multimedia Tools and Applications. 2020.79(8): 4289-4430.
[37] Shon S , Ali A , Glass J . Convolutional Neural Networks and Language Embeddings for End-to-End Dialect Recognition[C]. Odyssey 2018 The Speaker and Language Recognition Workshop. 2018:15-21.
[38] Kathania H K , Shahnawazuddin S , Ahmad W , et al. Role of Linear, Mel and Inverse-Mel Filterbanks in Automatic Recognition of Speech from High-Pitched Speakers[J]. Circuits Systems and Signal Processing.2019.21(03):7-19.
[39] Dieleman S , Schrauwen B . End-to-end learning for music audio[C]. IEEE International Conference on Acoustics. IEEE.2014:54-60.
[40] Wang Z , Li J , Chen X , et al. Musical Instrument Playing Technique Detection Based on FCN: Using Chinese Bowed-Stringed Instrument as an Example[J]. 2019.23(10):43-49.
[41] Pons J , Serra X . Randomly Weighted CNNs for (Music) Audio Classification[C]. ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and

中国知网 https://www.cnki.net

Signal Processing (ICASSP). IEEE.2019:54-61.

[42] 孔思聪. 基于 CNN 的多音调钢琴转录算法的研究与实现[D]. 华中科技大学.2019:40-59.

[43] Kim T , Lee J , Nam J . Comparison and Analysis of SampleCNN Architectures for Audio Classification[J]. IEEE Journal of Selected Topics in Signal Processing.2019.09(10):1-1.

[44] Yang L , Chen X , Tao L , et al. Multi-scale Fusion and Channel Weighted CNN for Acoustic Scene Classification[C].SPML '19: 2019 2nd International Conference on Signal Processing and Machine Learning(SPML). 2019:43-51.

[45] Chollet F. Xception: Deep Learning with Depthwise Separable Convolutions[C].2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE.2017:34-41.

[46] Wu X , He R , Sun Z , et al. A Light CNN for Deep Face Representation With Noisy Labels[J]. IEEE Transactions on Information Forensics and Security.2018.30(07):73-84.

[47] A M C , B I T , A A C , et al. Multi-head CNN–RNN for multi-time series anomaly detection: An industrial case study[J]. Neurocomputing.2019. 36(21):246-260.

[48] 刘建伟,宋志妍.循环神经网络研究综述[J].控制与决策,2022,37(11):2753-2768.DOI:10.13195/j.kzyjc.2021.1241.

中国知网 https://www.cnki.net